模型先行：人因驱动具身机器人研发中的「模型 → 验证 → 数据」路径

Model-First: A Model → Verification → Data Path for Human-Factors-Driven Embodied Robots

Yang Jinghong, Li Zhe

Sichuan Zhuangzhou Mengdie Technology & Culture Co., Ltd.

闵安娜 李哲 阳景宏

四川庄周梦蝶文化科技有限公司

2026 年 10 月 9 日

摘要

具身机器人要在开放的物理环境中工作 —— 环境不受控、任务不封闭、使用者各不相同。这类系统的研发有一个常被跳过的问题：先有什么？

通行的答案是「先有数据」—— 采集数据、训练或拟合模型、再做验证（记为「数据 → 模型 → 验证」）。这一顺序隐含一个前提：模型的质量取决于输入数据的质量。在受控场景下该前提可靠；但在开放物理环境中，数据本身并不纯净。更关键的是，污染发生在链条的源头 —— 验证位于其下游，只能观测后果，不能切断因果。

本文讨论另一个答案：如果先有模型呢？ 在这条路径上，模型不是从数据学来的，而是从对人的研究（Human Factors）设计而来；模型每天运行并产出结果，结果交由产品的外部体验者判定，只有通过判定的部分才沉淀为数据。本文把它记为「模型 → 验证 → 数据」，并论证：在这条路径上，模型是出发点，也是最重要的一环。

本文最硬的一段论证不依赖模型的内部实现。由于输出是为每个人单独生成的，每个数据点属于不同的对象，且是模型为该对象定制的产物 —— 这类数据既不能汇集，也不能反哺模型。因此在本场景中，「数据 → 模型」不是"不优"，而是"不可行"。

本文的贡献有三：①提出这条路径并与通行路径逐项对照，说明其结构性优势是污染阻断（结构上没有通道），而非"抗污染能力强"；②给出 14 条可复用的设计原则，每条配一个"违反它会怎样"的失败模式；③给出可证伪的检验方案（认输条件 + P1 – P15，其中七条可实操），并以一个真实产品做单案例研究。三类证据互不依赖 —— 结构性证据、可观察的行为取舍、一个真实案例；这也使本文成为一个软件工程问题：它讨论的是研发流程与验证 / 确认的设计，而不是模型算法。

本文主张这条路径可行，不主张它更优。证据是探索性的单案例研究，不设对照组、不做统计推断；结论限定在"该产品所服务的这一类自愿内测体验者"。因此本文对读者的要求，强度上限是"值得被问一次"，不是"必须改"：在设计自

己的系统时，把「先有什么」当成研发流程设计里一个必须先回答的问题，主动回答"模型从哪来"，而不是默认「先采数据」。

关键词：具身机器人；研发顺序；人因驱动；模型先行；数据污染；验证与确认；单案例研究；软件工程

Abstract

Embodied robots must operate in open physical environments — environments that are uncontrolled, tasks that are not closed-ended, and users who all differ. In developing such systems, there is a question that is often skipped: what comes first?

The conventional answer is “data first”: collect data, train or fit a model, then verify it (denoted “Data → Model → Verification”). This sequence carries an implicit premise: the quality of the model depends on the quality of the input data. In controlled settings this premise holds; but in open physical environments, the data themselves are not clean. More critically, contamination occurs at the source of the chain — verification sits downstream, able only to observe the consequences, not to cut off the cause.

This paper examines another answer: what if the model comes first? On this path, the model is not learned from data but designed from the study of people (Human Factors); the model runs every day and produces results, the results are judged by the product’s external testers, and only the parts that pass judgment settle into data. This paper denotes this path “Model → Verification → Data,” and argues that on this path the model is both the starting point and the most important link.

The paper’s most robust argument does not depend on the model’s internal implementation. Because the output is generated individually for each person, each data point belongs to a different subject and is a product the model customizes for that subject — such data can neither be pooled nor fed back into the model. Therefore, in this setting, “Data → Model” is not merely “suboptimal” but “infeasible.”

The paper makes three contributions: (1) it proposes this path and compares it item by item with the conventional one, showing that its structural advantage is contamination blocking (there is structurally no channel), not a “strong resistance to contamination”; (2) it offers 14 reusable design principles, each paired with a “what

happens if you violate it" failure mode; and (3) it provides a falsifiable verification scheme (concession conditions plus P1–P15, seven of which are practically executable) and conducts a single-case study of a real product. The three kinds of evidence are mutually independent — structural evidence, observable behavioral trade-offs, and one real case; this also makes the paper a software engineering problem: it addresses the design of the development process and of verification/validation, not model algorithms.

The paper claims that this path is feasible, not that it is superior. The evidence is an exploratory single-case study, with no control group and no statistical inference; the conclusion is bounded to "the class of voluntary beta testers that this product serves." Accordingly, the paper's demand on the reader is at most "worth asking once," not "must change": when designing your own system, treat "what comes first" as a question that must be answered in designing the development process, and proactively answer "where does the model come from," rather than defaulting to "collect data first."

Keywords: Embodied robots; Development sequence; Human-factors-driven; Model-first; Data contamination; Verification and validation; Single-case study; Software engineering

目录

第 1 章　引言 1

1.1 一个研发顺序上的选择 1

1.2 通行顺序及其结构性缺陷 1

1.2.1 通行顺序与其隐含前提 1

1.2.2 缺陷：污染的位置在源头 2

1.2.3 一个更硬的版本：在这个场景里它甚至不可行 2

1.3 本文主张的路径：模型 → 验证 → 数据 2

1.3.1 这条路径长什么样 2

1.3.2 三条理由，从弱到强 3

1.4 为什么这是一个软件工程问题 3

1.5 三条贡献 4

1.5.1 两条路径的逐项对照 5

1.6 主张范围：本文主张什么、不主张什么 5

1.7 全文结构 6

第 2 章　相关工作 8

2.1 五条脉络 8

2.1.1 脉络 1｜人因驱动的机器人研发 / HRI 8

2.1.2 脉络 2｜软件验证与确认（V&V） 8

2.1.3 脉络 3｜需求工程与人因需求 9

2.1.4 脉络 4｜data-centric AI 与 model-centric AI 10

2.1.5 脉络 5｜ML 系统工程化（MLOps / 数据治理 / 技术债） 10

2.2 本文落在五条脉络的交叉处 11

2.3 核心张力：本文与 data-centric AI 的关系 12
2.3.1 冲突在哪 12
2.3.2 但这不是"谁对谁错" 12
2.3.3 为什么"异端"这个位置反而有利 13
2.4 方法学归属：本文的验证形态落在 SCD / N-of-1 里 13
2.4.1 归属是什么 13
2.4.2 引用性质：这是"定位"，不是"依据" 14
2.4.3 那处空白是真的 14
2.5 本文与既有工作的差异：三处 14
2.6 小结 14
第 3 章　设计理念：以人为起点 16
3.1 两种研发顺序 16
3.2 从人的研究到算法：模型是理念的第一个可执行产物 17
3.3「反向定义」的含义 17
3.4「人 → 人」闭环 18
3.5 闭环在个体化生成下收得更紧 18
3.6 研究边界与主张范围 19
3.6.1 关于模型：陈述仅及来源 20
3.6.2 边界与论证的匹配 20
3.6.3 主张范围：可行，不是更优 21
3.7 理念与后文的关系 22
3.8 小结 22
第 4 章　框架：模型 → 验证 → 数据 24
4.1 两条路径 24
4.1.1 通行顺序及其结构性缺陷 24

4.1.2 本文讨论的顺序 25
4.1.3 逐项对照 25
4.2 双链结构：模型是铰接点 25
4.3 验证环节：机制、参与者与判据 26
4.3.1 执行机制 26
4.3.2 参与者：外部内测体验者 27
4.3.3 样本性质 27
4.3.4 判据的形态 28
4.3.5 运营的角色：透明通道 28
4.4 系统的构成：模型与语料库 29
4.4.1 系统 = 模型 + 语料库 29
4.4.2 语料库与反馈数据必须分开命名 29
4.4.3 语料库的两层结构及其现状 30
4.4.4 表达层尚未修正，对主链数据有一处已知影响 30
4.5 同一人群、双通道 31
4.5.1 两条通路，一个来源 31
4.5.2 分流是一道工序，且尚未运行 31
4.5.3 分流带来的风险：位置转移，而非消失 32
4.5.4 一个意外的好处，应正面写成论据 32
4.6 资源分配的优先序：一条行为证据 33
4.7 个体化生成：验证的形态被改写 33
4.7.1 事实 33
4.7.2 由此确立的结构性质 33
4.7.3 后果一：评分者间一致率在本场景下不适用 34
4.7.4 后果二：可靠性不能靠"多人一致"来保证 34

4.7.5 后果三：最硬的一段论证 ——「数据 → 模型」在本场景下结构上不可行 35
4.7.6 后果四：强化"模型最重要"，且属结构性证据 35
4.8「符合」的含义：验证的信息来源与判定的性质 36
4.8.1 验证的信息来源 36
4.8.2 判定的性质：预测 — 验证，不是自评 37
4.9「判据非自证」：三层支撑与四重排除 37
4.9.1 三层支撑 37
4.9.2 四重排除 38
4.9.3 两处必须保留的限定 38
4.9.4 由第 4 项立出的一条设计原则 39
4.10 免疫边界 39
4.11 小结：模型为什么是唯一源头 40
4.11.1 三类互相独立的证据 40
4.11.2 本章的落点与下一章 41
第 5 章　设计原则 42
5.1 十四条原则 42
5.1.1 四类分组 44
5.2 结构类原则：模型在系统里的位置 44
5.2.1 原则 1：模型先行 44
5.2.2 原则 4：模型承载价值 45
5.2.3 原则 8：模型自运行 45
5.3 流程类原则：数据如何产生 45
5.3.1 原则 2：验证前置 46
5.3.2 原则 3：数据后置且受控 46

5.3.3 原则 5：反馈可解释 46
5.3.4 原则 7：双通道分流（目标状态） 46
5.4 边界类原则：什么可以改、什么必须成文 47
5.4.1 原则 6：定义与表达分离 48
5.4.2 原则 9：判据显性化 48
5.5 防护类原则：如何保住判据的独立性 49
5.5.1 原则 10：判定者的外部性（被保护的对象） 49
5.5.2 原则 11：原料留存 49
5.5.3 原则 12：通道中立 50
5.5.4 原则 13：个体化判定 51
5.5.5 原则 14：陈述不引导 51
5.6 原则之间的依赖：谁保护谁 52
5.7 状态盘点：哪些原则已经在跑 52
5.8 本章小结 53
第 6 章　可检验命题 55
6.1 认输条件：先声明什么情况下本文是错的 55
6.1.1 一个未解的子项，以及本文如何回应它 56
6.2 命题清单 56
6.2.1 三条命题值得单独说明 58
6.3 七项可实操的检验设计 58
6.3.1 第一项：漏洞点内容编码（检验 P12） 59
6.3.2 第二项：错配对照（检验 P14） 60
6.3.3 第三项：个体符合率统计（检验 P9a） 60
6.3.4 第四项：判定者内稳定性重评（检验 P9b） 61
6.3.5 第五项：分流可行性检验（检验 P11） 61

6.3.6 第六项：判据来源盲预测（检验 P10） 61
6.3.7 第七项：信息增益与重合度编码（检验 P15） 62
6.4 一条应写进正文的方法论要点：评分者间一致率在本场景下不适用 62
6.4.1 这处替代方案的既有归属：SCD / N-of-1 63
6.4.2 可靠性由三条共同保证 64
6.5 命题、原则与结构事实的追溯 64
6.6 未列入清单的命题：P13 的撤回及其后果 65
6.7 本章小结 66
第 7 章　案例研究：产品数据作为证据 67
7.1 案例选择与研究设计 67
7.1.1 为什么是这一个案例 67
7.1.2 研究问题 68
7.1.3 设计的性质与它带来的边界 69
7.2 数据的来源、形态与收集清单 69
7.2.1 数据的来源与载体 69
7.2.2 两层结构：原始层与派生层 70
7.2.3 数据收集清单 70
7.3 九个分析动作 72
7.3.1 动作一：漏洞点内容编码（P12 / RQ8） 73
7.3.2 动作二：错配对照（P14 / RQ10） 73
7.3.3 动作三：个体符合率统计（P9a / RQ4a） 74
7.3.4 动作四：判定者内稳定性重评（P9b / RQ4b） 74
7.3.5 动作五：分流可行性检验（P11 / RQ7） 75
7.3.6 动作六：判定留痕 75
7.3.7 动作七：判据来源盲预测（P10 / RQ5） 75

7.3.8 动作八：信息增益与重合度编码（P15 / RQ11） 76
7.3.9 动作九：输出形式复核（第 14 条原则） 76
7.4 结果的呈现方式 77
7.4.1 反馈数据统计（表 7-5） 77
7.4.2 八条独立个案链（表 7-6） 77
7.4.3 一条反馈的完整走查 78
7.4.4 图 3：漏洞点类型分布 79
7.5 证据的边界 79
7.5.1 两处曾经的风险，现已排除 80
7.5.2 伦理与隐私 80
7.6 本章小结 80
第 8 章　讨论与有效性威胁 82
8.1 主张范围：本讨论的坐标系 82
8.2 两类局限：结构性 vs 参数性 83
8.2.1 结构性局限（本文的，共三条） 83
8.2.2 参数性局限（本文的，共四条） 84
8.3 有效性威胁 84
8.3.1 本文答不了的两条 86
8.4 已排除的四条质疑：转为正面表述 86
8.5 本文不主张什么 88
8.6 与既有研究的关系 89
8.6.1 本文落在五条脉络的交叉处 89
8.6.2 核心张力：本文在 data-centric AI 的语境下是"异端" 89
8.6.3 方法学归属：本文的验证形态落在 SCD / N-of-1 里 90
8.7 对未来工作的指引 90

8.8 小结 91
第 9 章　结论 93
9.1 本文主张了什么 93
9.1.1 一句话 93
9.1.2 三条贡献，以及各自被什么支撑 93
9.1.3 本文最硬的一段 93
9.2 本文没有主张什么 94
9.3 这条结论在什么条件下成立 94
9.4 希望读者读完做什么 95
9.4.1 一件事 95
9.4.2 为什么要求的强度只到这里 96
9.4.3 如果你决定这么做：可以拿走什么 96
9.5 下一步 97
9.6 一句话 97
参考文献 98

第 1 章　引言

1.1 一个研发顺序上的选择

具身机器人要在开放的物理环境里工作 —— 环境不受控、任务不封闭、用户各不相同。这类系统的研发有一个常被跳过的问题：

先有什么？

通行的答案是：先有数据。

采集数据 → 用数据训练或拟合模型 → 对模型做验证。记为「数据 → 模型 → 验证」。

本文要讨论的是另一个答案：如果先有模型呢？

模型 → 验证 → 数据 —— 先有模型（它来自对人的研究，而不是来自数据），模型每天运行并产出结果，结果交给真实体验者判断，只有通过判定的部分才沉淀为数据。

这不是"流程怎么排"的排布细节，而是一个决定整条链上每个环节性质的结构选择。

1.2 通行顺序及其结构性缺陷

1.2.1 通行顺序与其隐含前提

机器人系统研发中通行的顺序是「数据 → 模型 → 验证」：先采集数据，用数据训练或拟合模型，再对模型做验证。

这个顺序有一个隐含前提：

模型的质量取决于输入数据的质量。

在受控场景下，这个前提是可靠的 —— 数据可控、分布稳定、标注可查。但开放的物理环境不满足这些条件。

这个隐含前提不是本文虚构的靶子，它是一条有名字、有系统的路线：它以 data-centric AI 的形式被整理为完整的工程主张（[9] Zha et al. 2023；[10] Whang et al. 2023）。

本文并不认为它错。本文只主张：在"模型由人因研究设计而来"这一前提下，它不适用 —— 两者的适用域不同（详见第 2 章 2.3）。

1.2.2 缺陷：污染的位置在源头

在开放环境中，数据本身并不纯净。数据中可能存在注水数据、无效数据等污染源。

于是这个顺序暴露出一个结构性问题：污染的位置是源头。

数据（含污染） → 模型（被污染） → 验证（在污染之上做验证） → 下游全部继承

关键的一点：这个缺陷不是"数据质量工程做得不够好"。做得再好，也只是把污染压低，而不是消除。只要模型以数据为来源，"数据有多干净"就永远是模型质量的上限。

换句话说：问题不在数据够不够干净，而在"模型从数据来"这件事本身。

1.2.3 一个更硬的版本：在这个场景里它甚至不可行

以上是通行顺序的一般性缺陷。本文的场景里还有一个更硬的版本 —— 它使「数据 → 模型」不是"不优"，而是"不可行"。这一点留到 1.3.2 说明。

1.3 本文主张的路径：模型 → 验证 → 数据

1.3.1 这条路径长什么样

「模型 → 验证 → 数据」：

- 模型不来自数据，而来自对人的研究（Human Factors）；
- 模型每天自运行生成结果，结果交给外界的内测体验者判断 —— 他们回答的是"符不符合、是否和你今天的状态一致"；
- 只有通过判定的部分，才沉淀为数据。

在这条链上：

数据是产物，不是原料。

1.3.2 三条理由，从弱到强

（一）来源理由（弱）

模型来自对人的研究，不从数据来 → 先天不带数据污染。

故本文不靠它立论。

（二）价值理由（中）

系统的价值承载于模型。 系统 = 模型 + 语料库；但没有模型，语料库既无内容（没有可表述的东西），也无功能（没有可呈现的对象）。

本项目的输出是个体化生成的：模型为每个人单独生成结果，各人各收一份、各评各的。

由此推出：

每个数据点属于不同的对象，且是模型为该对象定制的产物。 这类数据既不能汇集（对象不同、无法对齐），也不能反哺模型（反哺等于要模型去学习自己的输出）。

故「数据 → 模型」在本场景下不是"不优"，而是"不可行"。

它是全文最难被反驳的一段（详见第 4 章 4.7.5）。

图 1　两条路径对照（上排：数据 → 模型 → 验证；下排：模型 → 验证 → 数据）〔图待绘制〕

1.4 为什么这是一个软件工程问题

一个容易产生的误解是：本文是一篇关于模型算法的论文。不是。

本文讨论的对象是研发流程的设计。 具体地：

表 1-3　本文的议题、所属软件工程领域，及其对应的既有传统

本文讨论的问题	它属于哪个 SE 议题	它对应的既有传统（示例文献）
判据从哪来 —— "符合预期"里的"预期"是什么	需求工程	需求工程与人因需求 —— [7] Viller et al. 1999； [8] Sutcliffe

		1998； [20] Maguire 2001
谁来判定、判定怎么传递、判定如何沉淀	验证与确认（V&V）	软件 V&V —— [4] IEEE 1012-2016； [5] ISO/IEC/IEEE 12207:2017； [6] Boehm 1984
哪些环节会被数据改变、哪些不会被改变	系统边界与数据治理	数据治理 —— [10] Whang et al. 2023； [14] Gebru et al. 2021
每一步的失败模式是什么、怎么防	设计原则	ML 系统工程化 —— [12] Sculley et al. 2015； [13] Kreuzberger et al. 2023

第三列的作用是"定位"，不是"依据" —— 它说明本文的每一项议题都落在既有的文献传统里，不说明这些文献支持本文的结论。本章不展开这些文献，详尽比对见第 2 章。

模型在这篇论文里是作为"链条上的一个位置"出现的，不是作为算法出现的。本文不讨论模型如何实现，也不描述那项人因研究怎么做 —— 这两者都不在本文的论述范围内（详见第 3 章 3.6）。

因此本文的落点是：一组关于流程与边界的设计判断。它的形式与 V&V、需求工程、ML 系统工程化的工作同构 —— 只是对象换成了"由人因研究设计出来的模型"。

1.5 三条贡献

表 1-4　本文的三条贡献

#	**贡献**	**落在哪一章**
C1	提出一条路径 —— 「模型 → 验证 → 数据」，与通行路径逐项对照（表 1-1），说明其结构性优势是污染阻断 （不是"抗污染能力强"）；并说明在个体化生成场景下，通行路径不是"不优"而是"不可行"	第 3、 4 章
C2	给出可复用的设计原则 —— 14 条，每条配一个「违反它会怎样」的失败模式。其中第 11 – 14 条属"已在运行"的原则（有事实支撑，非建议）；第	第 5 章

	7 条为目标状态	
C3	给出可证伪的检验方案 —— 3 条认输条件 + 14 条命题，其中七条是可实操的实证设计；并以一个真实产品做单案例研究，给出证据	第 6、 7 章

1.5.1 两条路径的逐项对照

表 1-1　两条路径的逐项对照（提要版；完整版见第 4 章表 4-1）

	通行路径	**本文路径**
顺序	数据 → 模型 → 验证	模型 → 验证 → 数据
模型的来源	数据	对人的研究（Human Factors）
污染位置	源头 （原始数据）	无（结构上进不来）
数据的状态	原料	产物
链条形态	闭环（数据持续训练模型）	单向、结构上封闭

两者的区别是：前者说的是没有通道，后者说的是通道存在但有防线。本文主张的是前者。

1.6 主张范围：本文主张什么、不主张什么

本文主张的是这条路径「可行」，不是它「更优」。 需要说清的是，「不主张更优」是一条关于举证责任的自我约束，不是对两条路径差异的否认。本文在 1.5.1（表 1-1）与 4.1.3（表 4-1）已把两条路径逐项并列：污染位置（源头 vs. 无通道）、数据状态（原料 vs. 产物）、链条形态（闭环 vs. 单向封闭） —— 三项差异都是结构性的，读者可逐条核对。本文的责任是把差异如实列出，不替读者对差异下优劣判语；差异是否构成优势，留给读者依据这些可核对的事实自行判断。本文仅在一处作出更强的判断：在个体化生成场景下，通行路径不是"不优"，而是"不可行"（1.2.3、4.7.5） —— 这是结构性事实，不是偏好。

表 1-5　本文的主张范围

	内容
本文主张	这条路径能走通；以模型为出发点是可行的

本文不主张	这条路径优于通行路径（更快 / 更省 / 更准 / 返工更少）
举证标准	主张"可行" → 存在性证明 （有一个真实案例走通了） → 不需要对照组

- 读者若以为本文在证明"更优"，会在第 7 章到处找不到对照组 —— 然后把这读成缺陷；
- 说清楚"我们主张可行"，第 7 章的单案例（一个真实产品、无平行对照）才站得住 —— 因为存在性证明只需要一个案例。

本文明确不主张的其他各条（完整清单见第 8 章 8.5）：不描述模型的内部实现、不描述人因研究的方法细节、不作机制性论证、不把"已内建于设计"写成"已被验证"。

1.7 全文结构

表 1-6　章节导览

章	**回答什么问题**
第 1 章　引言	为什么要换一个研发顺序 —— 通行顺序的缺陷、本文路径与三条贡献
第 2 章　相关工作	本文落在哪些既有脉络里
第 3 章　设计理念	模型从哪来 —— 为什么"模型不来自数据"是本文路径的前提
第 4 章　框架：模型 → 验证 → 数据	这条链是什么形状，每一环由什么派生（全篇地基）
第 5 章　设计原则	照这个形状做，要注意什么（14 条 + 失败模式）
第 6 章　可检验命题	这些主张能不能被证伪，怎么证（认输条件 + P1 – P15）
第 7 章　案例研究	在一个真实产品上，它成立到什么程度（数据位最集中）
第 8 章　讨论与有效性威胁	在什么范围内站得住，在什么范围内站不住
第 9 章　结论	收束主张，并指出下一步

阅读建议（按读者目的分三条路）：

- 关心方法：第 3 → 4 → 5 → 6 章；

- 关心证据：第 7 → 8 章；
- 只想知道结论：本章 1.1 – 1.3、1.5、1.6 + 第 9 章。

凡涉及模型内部机制的疑问，本文一律不答，也不作假设 —— 这不是省略，而是本文论证类型的规定：本文要证明的是位置关系，不是内部机制。

第 2 章　相关工作

2.1 五条脉络

2.1.1 脉络 1｜人因驱动的机器人研发 / HRI

这条脉络说的是：机器人系统应当以对人的理解为基础来设计，而不是以技术能力为起点（[1]–[3]）。

文献	在这条脉络里的位置
[1] Goodrich & Schultz (2008)	HRI 的奠基性综述，把"人"确立为机器人系统的核心议题
[2] Sheridan (2016)	明确呼吁人因学界介入 HRI，指出技术进展与人因理解的失衡
[3] He, Li & Chen (2017)	以人为中心的智能机器人设计综述，给出"人本"视角下的问题清单

本文取自它什么：本文的起点与这条脉络同源 —— 本文主张"模型来自对人的研究（Human Factors）"，这句话在 HRI 传统里不需要额外辩护（第 3 章 3.2）。

在这条脉络里，人因主要作用于"交互设计" —— 人怎么与机器人相处、界面如何、信任如何建立。 在本文里，人因作用于"模型的来源" —— 模型是从对人的研究中设计出来的。

换句话说：人因在本文中不是"评估维度"，而是"生成前提"。 在 HRI 里，人因回答"这个机器人好不好用"；在本文里，人因回答"这个模型从哪来"。

本文的差异在于人因所作用的那一环不同（交互层 vs 模型层）。

2.1.2 脉络 2｜软件验证与确认（V&V）

这条脉络说的是：系统的正确性要靠在生命周期中显式设计的验证与确认过程来保证，而不是靠事后检验（[4]–[6]）。

文献	在这条脉络里的位置
[4] IEEE Std 1012-2016	V&V 过程标准 —— 界定验证（建得对不对）与确认（建的是不是要的东西）的框架
[5] ISO/IEC/IEEE 12207:2017	生命周期过程标准 —— 把验证与确认固定为

	软件生命周期的标准过程
[6] Boehm (1984)	早期 V&V 经典 —— 强调验证要在需求与设计阶段就介入，而非等到测试

本文取自它什么：本文的"验证"完全落在这条传统里。 它具备 V&V 的三件要素 —— 判据（"符合预期"里的预期）、证据（判定结果与漏洞点）、可追溯（原始材料留存、判定可回溯到人）。

本文与它差在哪：

经典 V&V 假设判据可以事先写成规格 —— 于是验证 = 把产物对照规格。本文的判据是隐性的、未成文的，且判定者是不了解设计意图的外部体验者。

这带来一个 V&V 传统里少见的情形：

	经典 V&V	**本文**
判据的来源	事先写下的规格	隐性（未成文），可事后反推
判定者	相对独立于开发，但知道规格	外部体验者，不了解设计意图
验证的对象	产物是否符合规格	"符合预期"里的"预期"本身

因此本文的验证不只是"验证产物"，还把"判据本身"纳入了验证范围。这是本文与 V&V 传统的实质差异点，也是本文的一处贡献（第 5 章第 9 条原则、第 6 章 P11 的回溯性检验）。

2.1.3 脉络 3｜需求工程与人因需求

这条脉络说的是：系统的需求不只来自业务与技术，还来自对人的研究 —— 人的能力、限制、习惯与情境（[7]、[8]、[20]、[21]）。

文献	**在这条脉络里的位置**
[7] Viller, Bowers & Rodden (1999)	人因与需求工程交叉的经典综述 —— 系统梳理"哪些人类科学文献与可靠系统开发相关"
[8] Sutcliffe (1998)	场景法 —— 用场景获取与表达与人相关的需求
[20] Maguire (2001)	"以人为中心的设计"方法总览 （含情境分析与需求获取） —— 本篇脉络的主引
[21] Sutcliffe, Fickas & Sohlberg (2006)	PC-RE —— 处理个人与情境化需求的需求工程方法

本文取自它什么："判据源于对人的研究"是需求工程的一个老问题的新形态。本文第 3 章说"模型由人因研究设计而来"，这在需求工程语境里是可理解的 —— 它只是把"需求从哪来"这一老问题，推进到了"模型从哪来"。

文献 [21]（PC-RE）处理的是"需求获取阶段"的个人化 —— 不同的人有不同的需求，所以需求分析要考虑个体差异。 本文处理的是"输出生成阶段"的个体化 —— 同一个系统，为不同的使用者生成不同的内容，然后各自验收。

两者同题不同段。因此：

2.1.4 脉络 4｜data-centric AI 与 model-centric AI

这条脉络说的是：模型的质量取决于数据的质量，因此工程投入应当放在数据上（采集、清洗、标注、治理），而不是只放在模型结构上（[9]–[11]）。

文献	在这条脉络里的位置
[9] Zha et al. (2023)	DCAI 系统综述 —— 梳理 data-centric 与 model-centric 两条路线的分野
[10] Whang et al. (2023)	数据收集与质量挑战综述 —— 从 data-centric 视角列出工程难题
[11] Motamedi et al. (2021)	数据工程视角的方案 —— 用更少的数据训练出可用的网络

本文与它直接冲突 —— 本文主张模型不取自数据，因此数据污染在结构上进不来。这与 DCAI 的默认前提正面相对。

但冲突是"有条件的"，不是"原则性的" —— 详见 2.3。

2.1.5 脉络 5｜ML 系统工程化（MLOps / 数据治理 / 技术债）

这条脉络说的是：把 ML 从"能跑的模型"变成"可靠的系统"，难点在系统层面的耦合与工程债，而不在算法本身（[12]–[15]）。

文献	在这条脉络里的位置
[12] Sculley et al. (2015)	技术债奠基文献 —— 诊断 ML 系统的债主要来自系统耦合，而非模型
[13] Kreuzberger et al. (2023)	MLOps 定义与架构的权威综述
[14] Gebru et al. (2021)	数据文档化（Datasheets） —— 数据治理与可

	追溯
[15] Sculley et al. (2014)	技术债概念的早期 ML 版本

本文取自它什么：诊断同构，对象不同。 这条脉络的核心诊断是"问题出在系统结构，不出在单点技术"；本文的核心论证（"污染的位置在源头，问题不在数据够不够干净"）用的是同一类推理。

本文与它差在哪：

MLOps 关心"怎么把模型可靠地运维起来" —— 部署、监控、回滚、版本。本文关心"模型从哪来、数据是什么性质" —— 这是流程与边界的设计，不是运维。

一处容易被误读的地方：本文第 5 章的 14 条原则不是运维清单，也不是 MLOps 实践的替代品。它们回答的是"照这个链条形状做，要注意什么"，而不是"怎么把这个系统跑稳"。

2.2 本文落在五条脉络的交叉处

表 2-1　五条脉络 × 本文取什么 / 差在哪

脉络	**本文取自它什么**	**本文与它差在哪**	**差异的性质**
① 人因驱动的机器人研发	"以对人的理解为基础"这一起点	人因的作用位置：交互层 → 模型层 （人因是生成前提，不是评估维度）	位置差异
② 软件 V&V	判据 / 证据 / 可追溯三件要素	判据的性质与判定者的位置：事先可写规格 → 隐性未成文 + 判定者外部； 判据本身成为被验证对象	位置差异
③ 需求工程与人因需求	"需求可来自对人的研究"这一观念	个人化的阶段：需求获取 → 输出生成（同题不同段）	阶段差异
④ data-centric AI	（不取自它）	正面冲突：模型从数据来 → 模型不取自数据	前提差异
⑤ ML 系统工程化	"问题出在系统结构"这一诊断方式	对象：运维与工具链 → 流程与边界的设计	对象差异

这决定了本文在文献中的姿态：

- 对①②③⑤ —— 本文是推进（把某个既有观念用在链条的另一个位置上）；
- 对④ —— 本文是边界条件（划出一块 DCAI 不适用或不必适用的区域）。

两类姿态的举证责任不同："推进"要说明推进到哪；"边界"要说明边界在哪、条件是什么。后者更危险 —— 因为它容易被读成"你在否定主流"。

2.3 核心张力：本文与 data-centric AI 的关系

2.3.1 冲突在哪

data-centric AI 的核心主张：模型的质量取决于数据的质量 → 把工程投入放在数据上。

本文的主张：模型不取自数据，而来自对人的研究 → 数据污染在结构上进不来。

表 2-2　两条路线的前提对照

	data-centric AI	**本文**
模型从哪来	从数据学来 / 拟合而来	由人因研究设计而来
数据的性质	原料 （模型的上游）	产物 （模型的下游）
污染的位置	源头（原始数据）	无（结构上进不来）
工程投入的落点	数据采集 / 清洗 / 标注 / 治理	模型输出的正确性
链条形态	闭环（数据持续训练模型）	单向、结构上封闭

2.3.2 但这不是"谁对谁错"

本文明确不主张 data-centric AI 是错的。 本文只主张：

在"模型由人因研究设计而来"这一前提下，data-centric 的那条路径不适用。

理由：两条路线运作在不同的前提上。 DCAI 的前提是"模型是学来的"；本文的前提是"模型是设计出来的"。一旦模型不是从数据学来的，"提升数据质量以提升模型"这条路径在本文的场景里根本不存在 —— 不是它不好，而是没有那个通道。

这个前提本身是有条件的，条件写在本文的边界表里（第 8 章 8.5 第 2、3 条）：本文不描述那项人因研究怎么做，也不描述模型的内部实现。因此本文说的是"在这样一个前提下" —— 而不是"在任何情况下"。

2.3.3 为什么"异端"这个位置反而有利

本文在 data-centric 的语境下是少数派。这看似不利，实则有三个好处：

1. 边界条件比竞争者更容易被引用 —— 一个与主流前提冲突的框架，只要把适用条件写清楚，就能作为"在什么情况下不适用"被引用。含糊的赞同没有引用价值，清晰的边界有。
2. 它迫使本文把前提写出来 —— 而前提写出来之后，读者才能判断自己是否处在那个前提之下。这是本文主张范围纪律（第 8 章 8.1）的文献学收益。
3. 它把"分歧"从立场问题降级为条件问题 —— 本文与 DCAI 的分歧不需要任何一方让步：两者的适用域不同。

本文的案例是单产品、单团队的，外推范围限于"这一类研发路径"（第 8 章 8.3）。

2.4 方法学归属：本文的验证形态落在 SCD / N-of-1 里

2.4.1 归属是什么

本文的验证形态是"每人各评各的、无共同评分对象"。这一形态在方法学上落在既有的「单被试设计（single-case design, SCD）/ N-of-1 trial」框架内 —— 该框架以单个个体为分析单位，其设计前提正是"不把跨个体的观测汇总为对同一对象的重复测量"。该框架有成文的报告规范（[18]、[19]）。

表 2-3　两处报告规范

文献	内容
[18]　Vohra, S., et al. (2015). CONSORT extension for reporting N-of-1 trials (CENT) 2015 Statement. BMJ, 350 , h1738.	N-of-1 试验的报告规范
[19]　Tate, R. L., et al. (2016). The Single-Case Reporting Guideline In BEhavioural Interventions (SCRIBE) 2016 Statement. American Journal of Occupational Therapy, 70 (4), 544 – 555.	

2.4.2 引用性质：这是"定位"，不是"依据"

它说明本文的验证形态有方法学归属，不说明本文的结论已被该传统支持。

本文的结论仍只由第 3–7 章自己的证据支撑。

2.4.3 那处空白是真的

未找到专门针对"AI 个性化生成内容"的评估方法学文献。 这意味着：

一处方法学的界定："没找到"不等于"不存在"。

2.5 本文与既有工作的差异：三处

把 2.1–2.4 的差异收敛成三条，它们分别对应本文的三条贡献（第 1 章 1.5、第 9 章 9.1.2）：

表 2-4　三处差异与对应贡献

#	差异	相对于哪条脉络	对应贡献
D1	人因的作用位置：从"评估维度"移到"生成前提"	脉络 ①	C1 （提出路径）
D2	数据的性质：从"原料"变为"产物"；污染无通道可入	脉络 ④	C1
D3	分析单位：从"多人对同一对象的重复测量"变为"每人一条独立个案链"	脉络 ②③	C3 （检验方案）

它们是作用位置、对象性质与分析单位的差异 —— 本文只主张"在这个位置上、这样做是可行的"，不主张"这样比别的位置更好"（第 8 章 8.1）。

2.6 小结

本章做了三件事：

4. 把本文放进五条脉络（2.1）—— ①人因驱动的机器人研发；②软件 V&V；③需求工程与人因需求；④data-centric AI；⑤ML 系统工程化。

5. 逐条说清差异，并指出差异的性质（2.2）—— 四条是位置 / 阶段 / 对象的差异，只有一条（④）是前提的冲突。对前者本文是"推进"，对后者本文是"边界条件"。
6. 给出方法学归属，并限定引用性质（2.4）—— 本文的验证形态落在 SCD / N-of-1 框架内（定位，不是依据），而"AI 个性化生成内容的评估"确是一处空白。

本文的位置是"交叉处的边界条件" —— 它站在人因传统与 V&V 传统的交叉处，在 data-centric AI 的前提之外，主张一条以模型为出发点的路径是可行的。

本章不评价既有工作的优劣。本文与它们的差异是位置差异，不是水平差异。

第 3 章　设计理念：以人为起点

本文掌握产品的设计理念及基于该理念产出的产品数据；产品内部模型的具体实现与人因研究的方法细节，均不在本文的证据范围内。这两处共同覆盖了研发链条的中段。

本章能说的是"理念是什么、模型在链条的什么位置"，不能说的是"研究是怎么做的、算法是怎么实现的"。这不是回避，而是把陈述范围限定在可被读者独立检验的材料上 —— 这条规矩本身在 3.6.2 会成为一个正面论点。

3.1 两种研发顺序

机器人研发有两种可能的起手式，它们的差别不在技术栈，而在"人"被放在什么位置。

表 3-1　两种研发顺序的对照

	常规顺序	**人因驱动顺序**
第一步	定硬件与形态、写算法	研究人
第二步	做功能、调性能	依据研究结论反向定义机器人的形态与行为
第三步	交给用户，看能否接受	做功能、调性能
第四步	依反馈修补	交给用户，看能否接受
"人"的位置	末端 —— 验收者	起点 —— 依据

在常规顺序里，"人"出现在链条末端：机器已经成形，人负责判断它好不好用。人的角色是验收者 —— 他对设计的影响只能通过"接受 / 不接受"这一个通道，且发生在设计已经完成之后。

在人因驱动顺序里，"人"出现在链条起点：先研究人的情绪节律、社交习惯、家庭交互需求，再据此反向定义机器人的外形、动作、心智模型、对话逻辑。人的角色是依据 —— 设计从他身上推导出来，而不是由他事后评判。

这个位置差别是本文全篇的起点。 第 4 章要讲的验证，其判定者同样是"人"（外部内测体验者）；而本章要讲的依据，其来源也是"人"。两端都落在"人"上，中间那段由模型承担（见 3.4）。

3.2 从人的研究到算法：模型是理念的第一个可执行产物

理念本身不能运行。

要把"关于人的理解"变成系统里真正起作用的东西，必须先把它固化成一段可执行的规则（[17] von Neumann 1958 曾以"人脑与计算机"为题讨论过这组关系；此处只作定位）。这段规则就是模型。

- 模型 = 算法 —— 它是被设计出来的，不是被数据拟合出来的。
- 模型是设计理念的第一个可执行产物 —— 在它之前，理念只是一组主张；在它之后，系统才第一次"动起来"。

由此得到一条位置性的表述，它是本章要交给第 4 章的东西：

模型不是链条上的一环，它是链条的起点。 在它的上游是"人"（依据），在它的下游是验证与数据（产物）。

这里只说位置，不说过程。可以陈述"模型出现在'对人的研究'之后、系统的运行之前"，不陈述这段算法是如何被构造出来的 —— 后者不在本文的可见范围之内（见 3.6）。

本文没有材料支撑这两者，写成那样会立刻在审稿中被击穿。

3.3「反向定义」的含义

"反向"是相对于常规顺序而言的：常规是先有机器、再问人能否接受；人因驱动是先有对人的理解、再据此定义机器该是什么样。

被定义的对象：机器人的外形、动作、心智模型、对话逻辑。

定义的依据：关于人的研究结论。

于是在理念层面可以确立一条方向：依据在"人"的一侧，被定义物在"机器"的一侧 —— 定义的方向是从人到机器，而不是从机器到人。

这条方向对后文的意义：它解释了为什么本文路径的起点必须是模型而不是数据。如果定义的方向是从人到机器，那么"人 → （规则化） → 模型"这一段就是链条的入口；数据出现在链条的出口，它没有机会回到入口（第 4 章把这一点讲成"单向、结构上封闭"）。

仍属理念层面：本节说明"依据在哪一侧、定义朝哪个方向"，不描述这些结论是如何被研究出来的。

3.4「人 ↛ 人」闭环

把 3.1 和 3.2 接起来，会看到一个对称：

- 起点：对"人"的研究 —— 理念的依据来自人；
- 终点：第 4 章要讲的验证，其判定者也是"人"（外部内测体验者，产品的真实体验者）。

两端都落在"人"上。中间那段由模型承担 —— 模型是这段「人 → 人」的可执行载体：它把关于"人"的知识，变成系统里可运行的东西；再由"人"来判定它给出的结果是否成立。

这条闭环有一个方法论后果，它是本文最好用的一条结构性论据：

"人"既是依据的来源，也是判定的来源。

也就是说，判定标准不是设计方自己定的、也不是模型自己生成的，而是从"人"这一侧来的。对"自己定标准、自己判"（循环论证）的质疑，因此在结构上就不成立 —— 判定者不了解设计意图，他的判定不是设计方的自我确认。

精确表述（不可含糊）：起点与终点落在同一个"人"的层面上，但不是同一个人。起点是"关于人的研究结论"，终点是"某一个具体体验者的判定"。3.5 会把这一点说得更准。

3.5 闭环在个体化生成下收得更紧

上述闭环还可以再收紧一步。

产品的模型是为每个人单独生成结果的（每个人各收一份、各评各的）。这意味着闭环不是"人（一般）→ 人（一般）"，而是：

人（一般）→ 这个人本人

- 模型要做的事是：把关于人的一般知识，翻译成对这一个具体人的刻画；
- 终点是这个人本人认不认账。

闭环的两端因此落在同一个"人"的层面上：起点是对人的研究，终点是人的认可；中间那一段，是把"关于人的知识"对准"这个人"的工作。

模型要能对准个体，前提是它对人（一般）的研究足够深。若对"人"的刻画本身是错的，那么对准个体也无从谈起 —— 报告不符合，那条数据就没有价值。

这一点在第 4 章会成为"模型最重要"的结构性证据：模型必须同时承担对人建模与为个体生成两件事，而下游全部数据的价值，都取决于这两件事做得对不对。本章只把它作为理念的推论提出，不在此处展开论证。

3.6 研究边界与主张范围

本文的证据基础有一处结构性的特点 —— 研发链条的中段不在本文的可见范围内，且这一段由相邻的两个环节构成：

表 3-2　本文的证据可见范围

区段	本文是否可见	内容
设计理念（上游）	可见	本章所陈述的一切
人因研究的方法与产出形式	不可见 —— 属内部人员所掌握	如何研究人、得出何种结论
模型的内部实现	不可见	结构、损失、参数量、训练数据规模
验证流程	可见	谁判定、怎么传、怎么沉淀（第 4 章）
反馈数据（下游）	可见	判定的沉淀（第 7 章）

由此，本章的陈述范围有三条边界：

7. 其一，不涉及人因研究的方法与产出形式。本文可以声明"模型由人因研究设计而来" —— 这是一条关于来源的声明，属设计理念的一部分；但该研究如何进行、得出何种结论，本文不作陈述。

8. 其二，不涉及模型的内部实现。结构、损失、参数量、训练数据规模一律不予引用。
9. 其三，不作机制性论证。不主张"为什么这样设计会有效"。

前两条指向同一件事：本文知道来源，不掌握过程。对"模型从哪来"，本文的回答是溯源性的（它来自对人的研究），而非方法性的（它是如何被研究出来的）。

3.6.1 关于模型：陈述仅及来源

把上述边界收到最紧，本文关于模型的陈述只剩一条：

模型由人因研究设计而来；除此之外，本文不对模型作任何陈述。

这一陈述有三点需要说明：

10. 其一，它是来源声明，不是机制陈述。它说明模型从何而来，不说明模型是什么。本文据此可以主张"模型不来自数据"，但不主张任何关于模型自身性质的判断。
11. 其二，"不作陈述"是字面意义上的。内部实现、构造过程，以及那项人因研究本身如何进行，三者均不在本文的证据范围内；本文不对其作任何假设，包括"它们必然合理"这一默认假设。
12. 其三，论证所需的知识，与本文实际掌握的证据恰好重合。

3.6.2 边界与论证的匹配

就论证结构而言，这两处不可见的区段位置值得单独说明：

它们恰好落在本文论证所不需要的位置。

本文对"模型最重要"的论证仅用三类证据，且三类均不依赖链条中段：

13. 结构性证据 —— 数据在结构上无法反哺模型（由个体化生成推出）；
14. 行为类证据之一 —— 资源分配的优先序（修正成本很低的一环被有意推迟，资源投向模型的正确输出）；
15. 行为类证据之二 —— 用户主动输入一次即枯竭，而模型输出持续且每日不同。

三类证据分别落在链条结构、可观察的取舍与输入输出的量级对比上，均在本文的可见范围之内。

因此，这些不可见的区段不构成论证的缺口。本文据此对陈述范围设一条准则：

若一条论断必须借助中段细节才能成立，本文即不主张它。

这条准则使本文的主张范围窄于其可能触及的范围。由此得到的性质是：每一条保留的主张都落在读者可以独立检验的材料上 —— 链条结构、可公开陈述的流程，以及作者掌握的产品数据。对一项证据基础只覆盖部分环节的案例研究而言，这是必要的陈述纪律。

3.6.3 主张范围：可行，不是更优

上述边界直接决定全文主张的强度。

本文主张这条路径「可行」，不主张它「更优」。这一区分划定的是举证责任，而非结论方向："更优"需要对照组，而本项目没有对照组；两条路径本身的优劣，由第 1 章表 1-1 与第 4 章表 4-1 逐项列出的结构性差异呈现，本文不对其作优劣判断。其中一处差异无需对照组即可成立：在个体化生成场景下，「数据 → 模型 → 验证」不是"不优"，而是"不可行"（4.7.5）。本文的主张均建立在这类结构性事实之上。

表 3-3　本文主张什么、不主张什么

	内容
本文主张	这条路径能走通；以模型为出发点是可行的
本文不主张	这条路径优于传统路径（更快 / 更省 / 更准 / 返工更少）

由此得到本文的举证标准：

- 主张"可行" → 举证标准是存在性证明：有一个真实案例走通了即可，不需要对照组。
- 主张"更优" → 才需要对照组与返工实测。

本项目从未运行传统流程，因此没有返工实测数据。按表 3-3，这与主张范围相匹配，不构成缺陷；只要不越出主张范围去声称"更优"，这一"缺失"即不成立为问题。

3.7 理念与后文的关系

本章给出"为什么这样做"；第 4 – 7 章给出"这样做意味着什么、能不能被检验、在真实数据上成立到什么程度"。

表 3-4　本章与后文各章的关系

章	与本章的关系
第 4 章　框架	把 3.2 的"模型是起点"变成链条结构：模型 → 验证 → 数据，单向、结构上封闭
第 5 章　设计原则	把理念落成可操作的条目，并逐条给出"违反它会怎样"
第 6 章　可检验命题	把理念的每一环变成可证伪的命题，并给出检验设计
第 7 章　案例研究	把理念放到一个真实产品上，回答它成立到什么程度

一旦开始解释有效性，就需要方法细节与实现细节，而两者都不在认识域内 —— 那会是全文最容易被击穿的一段。本章的边界越干净，第 4 章的结构论证就越有力量。

3.8 小结

本章立了三件事：

16. 本文路径的前提是"模型不来自数据"。 模型来自对人的研究。这条前提是本文路径与「数据 → 模型 → 验证」路径的分水岭 —— 若模型由数据训练而来，链条就是闭环的，"以模型为出发点"无从谈起。
17. 模型是理念的第一个可执行产物。 理念要进入系统，必须先固化为一段可执行的规则；这段规则就是模型。模型因此不是链条上的一环，而是链条的起点。
18. 本章只作理念层面的陈述。人因研究的方法细节与模型的实现细节同属本文的可见范围之外，本文不主张；而本文的核心论证不需要它们 —— 这两处不可见的区段恰好落在论证所不需要的位置。

19. 本文主张的是「可行」，不是「更优」。举证标准因此是存在性证明，不需要对照组。 —— "从未运行传统流程、无返工实测"与主张范围相匹配，不构成威胁

在链条的上游，"人"是依据；在链条的下游，"人"是判定者；中间那段「人 → 人」由模型承担。第 4 章要论证的是：这一段为什么最重要，以及为什么它不能被反过来。

第 4 章　框架：模型 → 验证 → 数据

本文的证据基础包含本项目的设计理念，以及基于该理念产出的产品数据；产品内部模型的具体实现与人因研究的方法细节不在其内（后者属内部人员所掌握）。关于模型，本文的陈述仅及来源 ——"它由人因研究设计而来"；除此之外不作任何陈述（详见第 3 章 3.6）。

因此本章对模型一律只作结构性 / 位置性论证 —— 它在链条中处在什么位置、链条下游有哪些东西由它派生、把它移除之后什么会不存在。凡需引用模型内部指标（损失、参数量、训练数据规模等）的论断，本章一概不用。这不是回避，而是本章论证类型的规定：本章要证明的是位置关系，不是内部机制。

本章主张的是这条路径「可行」，不是它「更优」。 举证标准因此是存在性证明（有一个真实案例走通了），不需要对照组。

4.1 两条路径

4.1.1 通行顺序及其结构性缺陷

机器人系统研发中通行的顺序是「数据 → 模型 → 验证」：先采集数据，用数据训练或拟合模型，再对模型做验证。这一顺序有一个隐含前提：模型的质量取决于输入数据的质量。

这一前提在受控场景下是可靠的，但在开放的物理环境中会引入一个结构性问题：数据本身并不纯净。数据中可能存在注水数据与无效数据；而这些污染一旦进入训练流程，就会直接传给模型。更关键的是，这种污染发生在链条的源头 —— 后续的验证环节虽然可以发现模型表现不佳，但无法把污染从模型里剔除出去，因为验证发生在污染之后。

需要说明的是，本文的批评不是"数据驱动的方法抗污染能力弱"。抗污染能力是一个程度问题，而这里的问题是没有通道可关。在「数据 → 模型 → 验证」的顺序里，数据到模型这条边是敞开的，污染沿着它必然流过；验证环节位于其下游，只能观测后果，不能切断因果。

4.1.2 本文讨论的顺序

本文讨论的是另一个顺序：「模型 → 验证 → 数据」。

它的前提与前者不同：模型不是从数据学来的，而是从对人的研究（Human Factors）设计出来的。人因研究提供的是关于"人"的知识 —— 人的状态如何呈现、如何变化、如何被识别与表述；模型是这一研究的算法化产物。因此模型的来源先天不经过数据这一环。

在这个顺序里，验证的位置也变了：验证不再是"事后检验模型好不好"，而是把模型的产出筛成两类 —— 符合预期的记为有效反馈，不符合的记为漏洞点。只有通过这一筛选的部分，才沉淀为数据。

于是数据在这条链上的性质发生了根本改变：它是产物，不是原料。

4.1.3 逐项对照

两条路径的差异可以逐项列出（表 4-1）。

表 4-1　两条路径逐项对照（完整版；提要版见第 1 章表 1-1）

	传统路径	**本文路径**
顺序	数据 → 模型 → 验证	模型 → 验证 → 数据
模型的来源	数据	人因研究（对人的研究）
污染的位置	源头：原始数据	无 —— 结构上没有进入的通道
数据的状态	原料 （先于模型）	产物 （后于模型）
链条形态	闭环（数据持续训练模型）	单向、结构上封闭
数据的作用	塑造模型	记录验证结果，只读

图 1 给出两条路径的并列对照；图 2 是本文路径的主链图。

图 2　本文路径的主链图（模型 → 验证 → 数据，模型在视觉上占主导）〔图待绘制〕

4.2 双链结构：模型是铰接点

把上述顺序放回研发过程看，本项目实际存在两条链：

- 依据链：对人的研究（Human Factors） → 模型。人在模型的上游，是模型得以成立的依据。

- 实现链：模型 → 验证 → 数据。模型是这条链的起点。

模型是两条链的铰接点：它既是依据链的产物（由人因研究设计而来），又是实现链的源头（下游的一切由它派生）。本文的核心论点正是针对实现链而言的：在这条链的实现中，应以模型为出发点，且模型在这条链中最为重要。

这里有一个容易被忽略、但对回应"循环论证"质疑至关重要的结构事实，值得单独指出。

一条贯穿全篇的闭环人因研究研究的是"人"；验证所用的判据由"人"（外部内测体验者，见 4.3.2）给出；模型是这一段"人 → 人"之间的可执行载体。 于是判据的根在"人"，不在模型。这同时回答了两个问题："预期"从哪来（来自对人的研究），以及"自己定标准、自己判自己"的质疑为何不成立（判定的两端都是"人"，模型只是中间的载体，它不定义标准）。 又因为输出是为每个人单独生成的（见 4.7），这个闭环收得更紧：起点是"对人（Human Factors）的研究"，终点是"这个人本人认不认账" —— 首尾落在同一个"人"的层面上。

4.3 验证环节：机制、参与者与判据

4.3.1 执行机制

验证的定义是：验证「基于模型所给出的反馈」是否符合预期。符合 → 有效反馈；不符合 → 漏洞点。

本项目目前只有主链在运行，意见通路尚未接入（见 4.5）。

表 4-2　验证流程：现行状态与下一步状态

#	步骤	状态
1	模型每天自运行，生成结果	〔现行〕
2	结果通过微信交给判定者	〔现行〕
3	判定者通过微信回传"符不符合"	〔现行〕
4	不符合则给出不符合的点	〔现行〕
5	收集处理"结果的准确性 / 符合度" → 沉淀为反馈数据	〔现行〕 —— 这是目前唯一在跑的分流结果
6	运营对接：收集、汇总体验者的微信反馈	〔现行〕

7	判定者同时也提对表述的意见	〔下一步〕 —— 目前只有原始材料，未做提取
8	由运营同事「提取内核」，把两种反馈分成两路	〔 目标状态，尚未运行 〕 —— 归类规则未定
9	原始材料保留 （录音 / 选择 / 聊天）	〔现行〕 —— 为第 8 步留下可审计、可回溯的基础

流程中值得单独提出的一点，是一条可复用的经验：

渠道的选择决定了原料的可获得性。 本项目用现成渠道（微信）做验证，于是原始材料天然留存 —— 聊天记录本来就在，录音另有保存。第 8 步所需要的原料，几乎没有额外的采集成本。 换言之，"原料留存"这条原则（见第 5 章第 11 条）在本项目中几乎是免费获得的。若换成一个专门搭建的采集界面，原料的留存反而需要额外的设计与维护。这对做同类系统的团队是一条可直接搬走的经验。

4.3.2 参与者：外部内测体验者

判定者是外界的内测体验者 —— 产品的真实体验者，不是公司内部测试人员。

- 人数：8 人。
- 招募方式：网上发帖 → 对产品感兴趣者自愿报名。
- "既是参与者也是反馈者"的含义：他们是产品的体验者，同时由他们本人给出判定 —— 这是用户端的角色，不是公司内部的质检角色。

这一点值得展开，因为它与最初的直觉相反："外部性"是结构上的优点，不是风险。

外部体验者不了解设计意图。因此他们的判定不是设计方的自我确认，而是"这个人看了这份东西，认不认"。这保证了判据代表的是"人"，而不是"设计意图"。对"自己定标准、自己判自己"的质疑而言，这是一条结构性的反驳 —— 它不靠作者的声明，而靠"谁在判"这个可指认的事实。

4.3.3 样本性质

样本的招募方式决定了它的边界：

- 抽样方式 = 网上发帖 + 自愿报名 → 属自愿样本 / 便利抽样，非概率抽样。

- 优点：报名者是真正兴趣驱动的（不是朋友帮忙、不是内部人员）→ 外部性更实在。
- 风险 = 自选偏差（self-selection bias）：网上看到帖子并主动报名的人，可能偏向技术爱好者 / 早期采用者，未必代表普通用户。
- 规模定位：8 人属探索性小样本，用于探索与描述，不做统计推断。

4.3.4 判据的形态

判据是隐性、未成文的 —— 它活在体验者的判断里，不在文档里。

"预期"的来源是 Human Factors：判据的根在"人"（用户），人因研究正是对"人"的研究，模型是对该研究的算法化。因此 P2 需要一条限定：判据源于 Human Factors，但经由外部体验者的判断而生效。

针对"判据未成文"这一弱点，本项目有两条可用的回应，且都不需要重新采集数据：

20. 判据可事后反推成文。 体验者的原话就在聊天记录与录音里 —— 不必重新访谈，可直接从留存语料归纳。"未成文"不等于"不可复现"，它只意味着成文的动作被推迟了，而原料完好。
21. 分歧本身是信息。 判定者之间的分歧，指向的是判据里没说清的地方，而不是"判定不可靠"。这一点在 4.7 会以更精确的形式重新出现。

4.3.5 运营的角色：透明通道

运营同事参与流程，但只做记录：他把体验者的回复收集起来，并在询问时按 12 个方面逐条记为「符合 / 部分符合 / 不符合」。他不改写原话，不归纳出体验者没说的意思，也不向体验者解释模型的想法。

这一点很重要，因为它排除了一处可能被质疑的隐患：判定的内容完全由外部体验者给出，中间环节只做逐条记录，没有施加影响。运营是记录者，不是解释者，也不是判断者 —— 他不改变判定的内容，只把它落到「符合 / 部分符合 / 不符合」三个取值上。

不过，运营在流程中会承担两重角色，且分属两个阶段，必须分开写，否则容易被读成一件事（表 4-3）。

表 4-3　运营的两重角色

阶段	运营的角色	他影响什么	是否影响"外部性"
阶段一（现行）	记录者 —— 收集、记下，并逐条记为固定三值	什么都不影响 （透明通道）	不影响
阶段二（下一步）	归类者 —— 提取内核、分流	只影响"这条算判定还是意见"	不影响 （归类不改变判定内容）

即："外部性"（判定由谁形成）与"分类权"（判定被归到哪一类）是彻底分开的两件事。 前者在现行流程中已经完好；后者仍是下一步的待办。

4.4 系统的构成：模型与语料库

4.4.1 系统 = 模型 + 语料库

本项目的系统由两部分构成：模型 + 语料库。但两者的地位并不对等：

系统的价值承载于模型。没有模型，就没有语料库。

语料库的作用是把模型推演出的结果以更好的呈现形式表达出来，方便用户理解，并更准确地表述当前状态。也就是说，语料库依附于模型 —— 没有模型，它既无内容（没有可表述的东西），也无功能（没有可呈现的对象）。

4.4.2 语料库与反馈数据必须分开命名

「模型 → 验证 → 数据」这条链末端的"数据"，与系统内部的"语料库"，是两个完全不同的东西。如果二者都叫"数据库"，读者会把链末端的"数据"误认成语料库，从而误以为本文在主张某种数据回流。

因此本文为二者取定互不混淆的名称（表 4-4）。

表 4-4　语料库与反馈数据的区分

	语料库	反馈数据
归属	系统的一部分	验证环节的产物
来源	模型推演出的结果	判定者的判定 （有效反馈 / 漏洞点）
作用	把推演结果以更好的形式表达出来，更准确地表述当前状态	记录验证结果并统计

内部结构	两层：定义（免疫）+ 表达（可修正）	判定记录
与模型的关系	依附于模型	下游产物，与模型完全无关（不回流）
在链条上的位置	"占也不占" —— 不占主链的一格，但是模型下游、系统之内的组件	主链的终点

4.4.3 语料库的两层结构及其现状

语料库内部又分两层，且两层的现状与处理时机完全不同（表 4-5）。

表 4-5　语料库的两层结构

	定义层	**表达层**
状态	已确定	MVP 版本，尚粗糙
当前实际表现	不受数据影响（免疫）	会出现难以理解的文言文或抽象描述
"可改"的能力	——	能力具备，但未应用
为什么未应用	——	① 改起来很快 （成本低）；② "模型的正确输出"才是重点

表达层的一项意涵（由个体化生成推出，见 4.7）：由于输出是为每个人单独生成的，表达层要为每个人生成不同的表述。

但这也带来一个必须承认的依赖：生成规则的正确性依赖模型对个体的刻画。模型若给不出准确的个体状态，表达层也无从"准确表述当前状态"。 这是"模型最重要"的又一处体现。

4.4.4 表达层尚未修正，对主链数据有一处已知影响

表达层难懂这件事，会带来一个必须正面处理的后果：体验者在判定时，确实会读到难懂的表述。 于是"看不懂"有可能被判成"模型不对"。

这里要区分两条不同位置的风险：

- 分流环节的风险（事后归类时把两种反馈混在一起）→ 由"提取内核"这道工序挡住，面向阶段二。

- 判定环节的风险（体验者读到的表述影响了他的判断）→ 它位于分流的上游，分流挡不住，而且阶段一就在跑。

第二条是本节要处理的。好消息是它有数据可查，而且数据已经在手上：对现有反馈数据中的漏洞点做内容编码，统计"表达类抱怨"（看不懂 / 表述奇怪 / 太抽象）的占比。

- 占比低 → 正面证据：体验者能区分"模型不对"与"表述难懂"，主链数据是干净的；
- 占比高 → 必须如实报告，并把它写成"表达层待修对主链数据纯度的已知影响"。

两种结果都是收获。实测（见 7.3.1）：33 个漏洞点（27 个有记录）中"表达类抱怨"为 0；放宽到全部 122 条留存反馈记录，表述/呈现类困惑也仅 1 条（0.8%），且未转化为"不符合"。

4.5 同一人群、双通道

4.5.1 两条通路，一个来源

内测体验者在体验产品时，会产出两种东西：

- 判定（符合 / 不符合）→ 沉淀为反馈数据（主链）；
- 意见（对表述的看法）→ 作用于语料库的表达层。

两条通路的作用对象不同（一个作用于反馈数据、一个作用于表达形式），走的路也不同；但两种反馈出自同一批人。这一点若含糊，会被直接指为自相矛盾 —— 因为判定者本身也是体验者，两个角色在同一批人身上重叠。

4.5.2 分流是一道工序，且尚未运行

分通道不是由体验者自行分开提交的。判定与意见物理上走同一条通道（微信），没有被界面分开。因此"分流"的性质是事后归类，它取决于一道工序的质量：

体验者给出原始材料（判定与意见混在一起）→ 由运营同事「提取内核」→ 分成两路。

但这道工序目前尚未运行。现行只有主链在跑，意见只有原材料、未做提取，归类规则未定。它属于下一步工作。

4.5.3 分流带来的风险：位置转移，而非消失

把两种反馈分开，并不使风险消失，而是使它转移了位置：

- 原来：风险在体验者不自觉的混淆（把"这话说得别扭"当成"模型不对"）。
- 将来：风险在"提取内核"这一步的分类是否正确。

因此它是面向下一步的，不是当前的既成问题。

这是升级，不是取消。 原来的风险不可控（靠体验者自觉），将来的风险可控且可审计（一道有记录、有原始材料可对照的工序）。

为使这一升级真正成立，需要两条硬约束：

- 硬约束一：提取内核只做归类，不得改写判定内容。 违反 → 设计方通过"归类"实质改写了外部体验者的判定 → 外部性被绕过（第 5 章第 10 条原则失效）。
- 硬约束二：原始材料必须留存，且与归类结果可对照。 违反 → 归类不可审计，"只归类不改写"这条约束无从验证，等于没有。

混流造成的不是模型污染（模型不受任何影响），而是反馈数据的语义纯度被污染。

4.5.4 一个意外的好处，应正面写成论据

表达通路尚未接入，看起来是缺一块，实际上带来一个好处：现阶段的数据恰好只覆盖主链，而这正是本文要论证的那条链。

由于"意见通路与主链无关"早已确认，意见通路未运行不影响主链证据的完整性 —— 反而使主链证据里不可能混入表达层的东西。

更进一步：主链不依赖表达通路即可独立运行，这本身就印证了"两条通路作用对象互不相干"。

4.6 资源分配的优先序：一条行为证据

在 4.4.3 中我们看到一个事实：表达层的修正成本很低（"很快"），但被有意推迟；资源投向的是模型的正确输出。

这个事实值得单独成段，因为它提供的是一类很难得的证据：

资源分配的优先序，本身就是"模型最重要"的行为证据。 在有限资源下，团队先保模型、后修表达。这不是一句主张，而是一个可观察的取舍。

为什么它有力？因为行为比宣言更难反驳。任何团队都可以声明"我们最重视模型"；但"把成本更低的活往后排、把资源压在模型的正确输出上"，是一个可以被外部观察到的选择。

本文因此从一开始就握有两类性质不同的证据：

- 结构性证据 —— 链条的每一环都由模型派生（见 4.7、4.11）；
- 行为类证据 —— 资源分配的优先序（本节）。

两类证据互相独立，却指向同一结论。在单案例研究中，这种情形并不常见。

4.7 个体化生成：验证的形态被改写

本节是本章最重的一节，也是全文最难被反驳的一段论证所在。

4.7.1 事实

本项目的输出是个体化生成的：模型为每一个人单独生成结果，每个人各自收到不同的结果、各评各的。

其原因是一个领域事实：每个人的状态、思想、内心都不一样，因此模型给出的必须是"符合他们自己的"报告结果。

4.7.2 由此确立的结构性质

验证不是"多人对同一对象的互评"，而是"模型对 N 个人各生成一份、各由本人验收一次"的 N 条独立个案链。

这个性质把本项目与常规的验证与确认（V&V）场景彻底区分开来（表 4-6）。

表 4-6　常规 V&V 与本项目的对照

	常规 V&V （多评分者对同一刺激）	**本项目（个体化生成）**
判定对象	同一批输出 （共同刺激，common stimuli）	每人各自一份、互不相同
判定单位	评分者 × 同一对象	对象 = 判定者本人
判定的含义	"这个输出好不好"	"这份东西是不是说中了我"
信度的来源	评分者间一致率	判定者自身认知的稳定性
8 人的性质	8 名评分者	8 条独立个案（case）

4.7.3 后果一：评分者间一致率在本场景下不适用

一致率（inter-rater reliability）的前提是共同评分对象。本项目不存在共同对象 —— 每个人拿到的是为他单独生成的那一份。因此该指标在数学上无从计算。

在个体化生成系统中，经典的评分者间一致率不适用。

这本身就是一个可被同行引用的贡献 —— 因为随着个体化生成在推荐、健康报告、个性化助手等场景中变得常见，这个陷阱会被越来越多地踩到。

替代方案（本场景下唯一可行的信度检验）：判定者内稳定性（intra-rater reliability / test–retest） —— 把某批历史输出隔一段时间再给同一个人看一次，看他是否仍给出同样的判定。

一处方法学归属（2026-10-08 补）：本文的验证形态落在既有的「单被试设计（SCD）/ N-of-1 trial」框架内，该框架有成文的报告规范（CENT 2015 / SCRIBE 2016）。故"一致率不适用"不是本文的孤立主张，而是一种已被方法学界承认的研究形态在新对象上的应用 —— 详见第 6 章 6.4.1。但引用它只作"定位"，不作"依据"。

4.7.4 后果二：可靠性不能靠"多人一致"来保证

既然一致率算不出，"符合 / 不符合"这个二分没有第二道把关这一代价就必须正面承认。但不能据此说"可靠性完全取决于体验者之间是否一致" —— 那句话的前提（有共同评分对象）在本场景下不成立。

本场景下，可靠性由三条共同保证：

22. 判定者内稳定性（见 4.7.3）—— 须回溯补做；
23. 判定确由本人作出 —— 判定由输出所指向的那个人本人给出，不是他人代判；
24. 传递环节不污染 —— 运营只做逐条记录，不解释、不改写判定内容（见 4.3.5）。

4.7.5 后果三：最硬的一段论证 ——「数据 → 模型」在本场景下结构上不可行

传统路径有一个隐含前提：数据是对同一对象的重复观测。正因为如此，数据才可以汇总成统一的训练集，才可以反哺模型。

本项目的实际情形与之不同：

- 每个数据点属于不同的对象（A 的数据来自 A 的报告，B 的数据来自 B 的报告）；
- 而且每个数据点都是模型为该对象定制的产物。

由此得到两个否定：

- 这些数据不能汇集 —— 对象不同，无法对齐。把 A 的符合率与 B 的符合率合并成一个数字，没有任何意义；
- 这些数据也不能反哺模型 —— 要反哺，就等于要模型去学习自己的输出。

结论：「模型 → 验证 → 数据」在这里不是价值选择，而是数据结构本身逼出来的唯一可行形态。

4.7.6 后果四：强化"模型最重要"，且属结构性证据

个体化生成要求模型同时做两件事：

25. 对人建模 —— 刻画这个人此刻的状态、思想、内心；
26. 把该状态翻译成这个人能懂的报告 —— 即语料库表达层的内容（见 4.4.3）。

于是有一个直接后果：只要模型对"人"的刻画错了，报告就不符合，数据就是垃圾。 数据的质量完全依赖模型对个体的正确性。

这构成一条结构性证据：模型是链条上唯一同时承担"对人建模"与"为个体生成"两个职责的环节，而这两个职责共同决定了下游一切的质量。

4.8「符合」的含义：验证的信息来源与判定的性质

4.7 说明了验证的形态。本节要钉死"符合"这个词在本文中的确切含义 —— 因为全部主链证据都建立在这个词之上。

4.8.1 验证的信息来源

事实：用户只提供一次初始值（"他填的东西、他自己说的话"），此后不再提供信息；模型独立推演 —— 从行为、状态、交互中看出用户没有主动告诉模型的东西；每天给出的东西都不一样。

- 用户主动提供的 —— 一次性，作为初始值，此后枯竭；
- 系统被动观测的 —— 行为、状态、交互；用户并不知情模型看到了什么。

由此钉死「符合」的定义：

用户在一次性提供初始值之后，看到模型自己推演出的、他从未告知过模型的东西，判断符不符合。 即：「符合」= 模型说中了他的状态，而不是模型复述了他的输入。

这一定义是全部主链证据的解释前提。

回声风险的三重排除。 若"符合"只是模型把输入还给用户，则判定没有信息量。本项目不成立，理由有三：

27. 输入端一次即枯竭 —— 没有"持续复述输入"的机会；
28. 素材端独立于自我陈述 —— 模型看到的来自用户未主动告知的观测，用户不知道模型看到了什么 → 模型说中了他才认账；
29. 输出端每天不同 —— 若只是回声，输出应当静止。

由此得到第三类证据。 把 4.8.1 的事实与 4.7.5 的结构合起来看：

用户主动输入一次即枯竭，模型输出却每日不同且持续。 输入端的信息量有限且一次性，输出端持续且变化 —— 差额只能由模型提供。

这是与核心论点咬合最紧的一条：数据端只提供一次起点，模型端负责全部后续内容。

4.8.2 判定的性质：预测 — 验证，不是自评

判定的问法是："符不符合，以及是否和你今天的状态一致。"

这句话把判定的性质精确化了，有三点：

第一，问的是"对不对"，不是"像不像"。 判定不是"这话像不像在说我"（那属于主观验证），而是可证伪的比对。

第二，参照物是体验者自己今天的实际状态。 判定因此是三分对照：

模型说 X → 体验者知道自己今天的状态是 Y → 问 X 是否 ≈ Y

关键在于：Y 是一个独立于模型的、也非设计方给定的量。 于是验证从「自评」升级为「对预测的验证」 —— 模型每天输出的是对"这个人今天状态"的一个预测，体验者用自己当天的状态去验证它。

第三，判定是"日粒度"的。 "今天"这个时间锚点使判定天然形成时间序列，可以支持趋势分析（符合率随时间的变化）与个体内跨日稳定性。

收益与代价。 收益方面："判据非自证"由此获得第二条支撑（见 4.9）；巴纳姆效应的严重程度下调 —— 问"对不对"远弱于问"像不像"，因为"今天的状态"多少仍是一个主观判断，所以不能完全排除，仍须检验。

4.9「判据非自证」：三层支撑与四重排除

4.9.1 三层支撑

"判据是不是自证"（即"是不是自己定标准、自己判自己"）是本文最核心的一处防守。它由三层支撑，每层都对应一条可观察的事实，而不是一句态度声明（表 4-7）。

表 4-7 「判据非自证」的三层支撑

#	支撑	对应的可观察事实	出处
①	判定者外部	谁判的 —— 由不了解设计意图的外部内测体验者给出	4.3.2 / 第 5 章第 10 条原则
②	判定对象外部	跟什么比 —— 比对的是他自己的今天状态，不是模型给的、	4.8.2

		也不是设计方定的	
③	判定素材不诱导	怎么给的 —— 模型只作客观陈述，无引导词汇	4.9.2 / 第 5 章第 14 条原则

4.9.2 四重排除

在确认这三层之前，"符合"曾被担心是四种自证机制造成的假象。四者现均已排除或已定位（表 4-8）。

表 4-8　四重排除

#	曾被担心的自证机制	排除依据	出处
1	回声 （把输入还回去）	用户主动输入一次即枯竭	4.8.1
2	回声 （持续复述）	输出每天不同 （若为回声应当静止）	4.8.1
3	巴纳姆效应 （描述模糊，人人觉得像）	问的是"对不对"而非"像不像" → 力度下调； 仍须进一步检验	4.8.2 / 第 6 章 P14
4	对照物污染 + 措辞诱导	参照物以体验者内省为主；模型只作客观陈述、无引导词汇	4.9.3

第 4 项值得展开，因为它包含一个比巴纳姆效应更隐蔽的机制：

- 对照物污染：如果模型对当日状态的描述塑造了体验者对"我今天状态"的认知，那么参照物 Y 就被模型污染了 —— 循环论证会换个位置重新出现。
- 措辞诱导（leading language）：即使模型确实说中了，诱导性的措辞（"你是不是觉得最近有点累？"）也会人为拉高符合率。它比巴纳姆效应更隐蔽 —— 巴纳姆靠描述模糊，诱导靠问法施压。

本项目的实际情况是：判定时的参照物以体验者内省为主；模型只是客观地给出当日状态，没有引导词汇。两个机制因此双双排除。

4.9.3 两处必须保留的限定

30. "大多数是内省" —— 是"大多数"，不是"全部"。少数情形下，参照物可能部分受到模型描述的影响。

31. 巴纳姆效应不能完全排除 —— "我今天的状态"本身仍是主观判断。因此相应的检验（第 6 章 P14，错配对照）仍要做。

4.9.4 由第 4 项立出的一条设计原则

"模型只作客观陈述、无引导词汇"这一事实，值得固化为一条设计原则（第 5 章第 14 条「陈述不引导」）：

模型的输出必须以陈述方式给出当日状态判断，不得使用引导性、暗示性措辞。

它与第 12 条「通道中立」构成一对：

- 第 12 条管"传递环节不污染" —— 中介只做逐条记录，不解释、不改写判定内容；
- 第 14 条管"输出环节不诱导" —— 模型只陈述，不征询认同。

两者共同保护第 10 条（判定者的外部性）。光有外部的判定者不够 —— 传递环节不污染、输出环节不诱导，外部性才算真正落地。

这条原则还有一个好处：它可被审稿人直接复核。输出的形式特征是可观察的 —— 可独立核对的陈述句（"你今天的状态是 X"）与征求认同的问句（"你今天是不是 X？"）在文本上一望即知。

4.10 免疫边界

前文多处用到"污染进不来"这一说法。这里必须界定它的范围 —— 否则会被读成一个过强的断言。

被免疫的是定义，不是表达（表 4-9）。

表 4-9　免疫边界

层	是否被数据 / 反馈改写	归属
定义 （语义内容、模型本身）	不改。若有变更，那是新一轮人因研究，不是数据回流	模型
表达 （呈现形式、表述方式）	可以改 —— 通过反馈修正，使其不出错、更准确	语料库

同时，链条的封闭性是彻底的：数据不回流修改模型，而且与模型无关 —— 连"设计者看到漏洞点后回去改模型"也不构成数据回流，那是新一轮的人因研究。

因此"污染进不来"在本文中只针对定义层。 表达层恰恰是可以且应当被反馈修正的 —— 这不但不与本文主张冲突，反而是本文路径的一个优点：该改的地方有通道，不该改的地方没有通道。

4.11 小结：模型为什么是唯一源头

本章的论证可以收束为一句结构描述：

链条上的一切下游 —— 判据、验证、数据、表达层 —— 都由模型单向派生；模型是这条链上唯一的源头。

这条描述不是一句态度，而是可逐环指认的：

- 判据源于人因研究，经模型承载 → 判据是模型的下游；
- 验证所比对的对象由模型生成 → 验证是模型的下游；
- 数据只有通过验证才成为数据 → 数据是产物，不是原料；
- 表达层依附于模型 —— 没有模型，它既无内容也无功能。

并且移除模型，下游不是"变差"，而是"不存在"。这是本章对"模型最重要"最精确的表述：它说的是位置关系，不是程度判断。

4.11.1 三类互相独立的证据

本章至此握有三类性质不同、互相独立、却指向同一结论的证据（表 4-10）。

表 4-10　三类互相独立的证据

	① 结构性证据	② 行为类证据之一	③ 行为类证据之二
内容	链条的每一环都由模型派生 —— 判据、验证、数据、表达层	资源分配的优先序 —— 表达层修正成本低却被有意推迟	用户主动输入一次即枯竭，模型输出却每日不同且持续
性质	可指认的结构事实	可观察的取舍	可观察的收支差额
为什么有力	移除模型则下游全部不存在	行为比宣言更难反驳	输入端信息量有限且一次性、输出端持续且变化， 差额只能由模型提供
出处	4.7.6、 4.11	4.6	4.8.1

在单案例研究中，同时握有三类独立证据的情形很少见。这是本文证据强度的来源。其中第 ③ 类与核心论点咬合最紧：数据端只提供一次起点，模型端负责全部后续内容。

4.11.2 本章的落点与下一章

本章确立的是结构。由此可以直接推出两章：

- 第 5 章（设计原则）：把本章各处已在本项目实际运行的做法，固化为可复用的原则 —— 其中第 11、12、13、14 条属"已在运行"的原则（有本章的事实支撑），第 7 条为"目标状态"；
- 第 6 章（可检验命题）：把本章的结构事实转化为可证伪的命题，并给出检验方案。

而本章结构本身的可证伪性可以这样表述：若任一派生关系被打破 —— 数据触到模型或定义，或使用者触到模型输出 —— 本路径即被证伪。 这一条件将在第 6 章展开为具体命题。

第 5 章　设计原则

与第 4 章相同：本章的一切原则都只涉及模型在系统中的位置、输入输出关系与边界，不涉及模型内部的任何机制或指标。关于模型，本文能说的只有一句——"它由人因研究设计而来"（详见第 3 章 3.6）。

本章的原则是为"这条路径可行"服务的做法条目，不是"这样比传统做法更好"的证明。本文主张"可行"、不主张"更优"（详见第 3 章 3.6.3）；故每条原则的失败模式写的是"违反它会破坏什么"，而不是"遵守它能带来多少收益"。

5.1 十四条原则

表 5-1　十四条设计原则与失败模式

#	原则	违反它会怎样（失败模式）
1	模型先行 —— 模型是人因研究的函数，不是数据的函数；模型在整个生命周期内不被数据改写	模型开始随运行数据漂移，路径退化为传统路径，本文全部论证的前提同时失效
2	验证前置 —— 任何反馈在成为数据之前，必须先经过判定	未经判定的反馈直接入库，数据即被污染，且污染无法在事后区分
3	数据后置且受控 —— 只有通过判定的有效反馈才进入反馈数据；漏洞点走另一条路径	漏洞点混入有效反馈，数据的统计含义失效 （"通过率"变成一个没有分母的数）
4	模型承载价值 —— 语料库依附于模型而存在	模型缺位后语料库既无内容也无功能，系统失去价值载体
5	反馈可解释 —— 不符合的反馈必须落到具体的「不符合的点」	只记"失败"而不记"失败在哪"，反馈不可归因、不可利用，验证退化为计数
6	定义与表达分离 —— 语义内容（定义）由模型单方面决定、不受数据影响；反馈只作用于表达形式	① 表达调整悄悄改写定义，污染经旁路进入；② 表达层粗糙反过来影响判定 —— 体验者把"看不懂"判成"模型不对"，渗入主链数据。后者发生在分流上游，提取内核挡不住
7	机制 = 由运营同事「提取内核」。	① 判定与意见混流 → 表达上的别扭被当成模型的不符合 → 反馈数据里混入本属于表

		达层的抱怨， 数据的语义纯度被破坏； ② 越界改写 → 判定的外部性被绕过； ③ 原始材料不留 → 前两条无从事后检查
8	模型自运行 —— 模型按自身规则与算法逻辑运行，使用者无法影响其输出	模型输出受使用行为扰动， "模型是唯一源头"不再成立
9	判据显性化 —— 判据必须从人因研究的结论落成文字，否则验证不可复核、判定分歧无法归因	判定分歧无法归因到具体条款；数据的可信度无法论证。当前状态：未成文，但具备落地条件 （见 5.4.2）
10	判定者的外部性 —— 判定必须由产品的真实体验者 （外界内测体验者）给出， 不是设计参与者、也不是公司内部测试人员	判定退化为设计方的自我确认：判据自己定、自己判，验证环节失去独立信息来源；"预期来自 Human Factors"变成空话。这是本章五条防护类原则共同保护的对象 （见 5.6）
11	原料留存 —— 当分流规则尚未确定时，先完整留存原始材料 （录音 / 选择 / 聊天），使未来的分类成为可能	原始材料不留 → 想建通路时无据可依，只能重新采集；第 7 条的两条硬约束永远无法被验证；第 9 条（判据反推成文）也一并失去基础
12	通道中立 —— 当判定经由中介 （如运营同事）收集时，中介只做逐条记录： 把体验者的回复按 12 个方面记为「符合 / 部分符合 / 不符合」，不解释、不改写	中介一旦解释或引导（"这个其实是 ……"） → 体验者的判定不再纯粹外部 → 第 10 条失效， "判据代表人不代表设计意图"这句核心论据从"结构上成立"退化为"程度上说不清"
13	个体化判定 —— 判定必须由输出所指向的那个人本人给出（因为输出是为他单独生成的）；判定不得跨个体汇总为"对同一对象的评分"	① 把 8 人的判定当作对同一模型的重复评分 → 会算出"评分者间一致率"这类在本场景下不成立的指标 → 数据被误读； ② 若改由他人代判 → 判定对象与判定者错位，判定本身失去意义
14	陈述不引导 —— 模型输出必须以陈述方式给出对当日状态的判断， 不得使用引导性、暗示性措辞 （"你是不是觉得 ……""你最近是不是有点 ……"）	即使模型真的说中了，诱导性措辞也会人为拉高符合率 → 判定失去区分度 → "验证"退化为"模型说什么用户都点头"。这是比巴纳姆效应更隐蔽的一种自证：巴纳姆靠描述模糊， 诱导靠问法施压

5.1.1 四类分组

十四条原则并非并列。按作用面可以分成四类，每一类回答一个不同的问题（表 5-2）。

表 5-2　十四条原则的四个层次

层次	包含	回答的问题
① 结构类	1、4、8	模型在系统里处在什么位置
② 流程类	2、3、5、7	数据如何产生
③ 边界类	6、9	什么可以改、什么必须成文
④ 防护类	10、11、12、13、14	如何保住判据的独立性

这个分组不是分类癖。它对应一条因果顺序：结构决定流程，流程暴露边界，边界需要防护。下面四节按此顺序展开。

两组需要特别说明的状态标记：

- 第 7 条是"目标状态" —— 机制与硬约束已定，但尚未运行。
- 第 13、14 条由项目事实推导而来（分别由个体化生成与"无引导词汇"这两条事实推出），尚待项目方确认。若确认，它们与第 10、11、12 条同属"已在运行"；若不确认，本文的防护类原则将由五条减为三条。

5.2 结构类原则：模型在系统里的位置

三条结构类原则说的是同一件事的三个面：模型既不在数据的下游，也不与数据平行 —— 它在最上游，且独立于数据。

5.2.1 原则 1：模型先行

模型是人因研究的函数，不是数据的函数。

这条原则是整条路径的前提。第 4 章已经说明：模型来自对人的研究，不经过数据这一环；因此数据污染结构上没有进入模型的通道 —— 不是"抗污染能力强"，而是没有通道。

它还包含一个时间维度上的要求：模型在整个生命周期内不被数据改写。 这条约束常被误读为"模型永不更新"。其实不然 —— 模型当然可以更新，但更新的依据必须是新一轮的人因研究，而不是运行中产生的数据。两者的区别是可指认的：前者的输入是关于"人"的知识，后者的输入是模型的输出。

违反它会怎样：模型开始随运行数据漂移。此时链条退化为传统路径，第 4 章的污染阻断论证、下游派生论证、"模型最重要"的结构性论证同时失效 —— 本文的全部论证都以这条原则为前提。

5.2.2 原则 4：模型承载价值

语料库依附于模型而存在。

系统由模型 + 语料库两部分构成，但两者的地位并不对等。语料库的作用是把模型推演出的结果以更好的呈现形式表达出来，方便用户理解，并更准确地表述当前状态。也就是说，语料库没有自己的内容 —— 它的内容全部来自模型；也没有自己的判断 —— 它只负责表达。

违反它会怎样：一旦模型缺位，语料库既无内容（没有可表述的东西），也无功能（没有可呈现的对象）。系统失去价值载体，只剩下一个空的表述层。

5.2.3 原则 8：模型自运行

模型按自身规则与算法逻辑运行，使用者无法影响其输出。

这条原则把"模型是源头"落实为一条可检查的性质：模型的输出不受使用行为的扰动。体验者可以判定、可以提意见，但不能通过使用行为改变模型输出。

违反它会怎样：模型输出一旦受使用行为扰动，"模型是唯一源头"这句话就不成立了 —— 因为此时使用者成了另一个源头。第 4 章的三类证据中，第三类（输入一次即枯竭、输出持续且每日不同）会首先失效：若使用者能影响输出，"差额由模型提供"这个推论就不再唯一。

5.3 流程类原则：数据如何产生

流程类原则回答的是"数据从哪来"。它们的共同点是：数据是流程的末端产物，而不是起点。

5.3.1 原则 2：验证前置

任何反馈在成为数据之前，必须先经过判定。

这条原则界定了"反馈"与"数据"的界限：反馈是原材料，判定是它的准入手续。没有经过判定的反馈，只是被记录下来的东西，不是数据。

违反它会怎样：未经判定的反馈直接入库。此时数据即被污染，而且这种污染无法在事后区分 —— 因为库里没有任何标记能说明哪一条过了判定、哪一条没有。这与第 4 章说的"污染没有通道进来"并不矛盾：这里说的是流程上的准入，那里说的是结构上的通道。

5.3.2 原则 3：数据后置且受控

只有通过判定的有效反馈才进入反馈数据；漏洞点走另一条路径。

这条原则是第 2 条的推论，但它多了一层要求：通过判定的与未通过判定的，要分开走。 有效反馈进反馈数据；漏洞点另有去处。

违反它会怎样：漏洞点混入有效反馈，数据的统计含义失效。具体地说，"通过率"会变成一个没有分母的数 —— 因为分子分母混在同一个集合里，无法判断这个比率是在衡量什么。

5.3.3 原则 5：反馈可解释

不符合的反馈必须落到具体的「不符合的点」。

这条原则要求判定可归因：不能满足于记录"这次不符合"，而要记下"哪里不符合"。

违反它会怎样：只记"失败"而不记"失败在哪"，反馈不可归因、不可利用 —— 验证退化为一个计数动作，而不是一个诊断动作。这条原则也是第 9 条（判据显性化）的实践基础："不符合的点"积累起来，就是判据的事后反推材料。

5.3.4 原则 7：双通道分流（目标状态）

同一批体验者产生的两种反馈，必须在系统里分流：判定进反馈数据，意见进语料库表达层。

机制是由运营同事「提取内核」 —— 体验者给出原始材料（判定与意见混在一起），运营把它分成两路。

现行只有主链在跑：收集处理"结果的准确性 / 符合度"；意见只有原始材料、未做提取，归类规则未定。它属于下一步工作。

两条通路的作用对象不同（一个作用于反馈数据、一个作用于表达形式），但两种反馈出自同一批人。这一点若含糊，会被直接指为自相矛盾 —— 因为判定者本身也是体验者，两个角色在同一批人身上重叠。

性质：这是"事后归类"，不是"采集即分流"。 判定与意见物理上走同一条通道（微信），没有被界面分开。因此分流的质量取决于运营这道工序的可靠性。

两条硬约束：

- 硬约束一：提取内核只做归类，不得改写判定内容。 违反 → 设计方通过"归类"实质改写了外部体验者的判定 → 外部性被绕过（第 10 条失效）。
- 硬约束二：原始材料必须留存，且与归类结果可对照。 违反 → 归类不可审计，"只归类不改写"这条约束无从验证，等于没有。

风险的位置是转移，不是消失。原来的风险在体验者不自觉的混淆（把"这话说得别扭"当成"模型不对"）；将来的风险在"提取内核"这一步的分类是否正确。因此这是升级，不是取消 —— 原风险不可控（靠体验者自觉），将来的风险可控且可审计（一道有记录、有原始材料可对照的工序）。

落地前的一步：用留存的原始材料先做可行性检验 —— 先证明"两者能被稳定分开"，再决定是否建通路（见第 6 章 P11）。

违反它会怎样：①判定与意见混流 → 表达上的别扭被当成模型的不符合 → 数据的语义纯度被破坏；②提取内核越界改写 → 判定的外部性名存实亡；③原始材料不留 → 前两条都无法被事后检查。

5.4 边界类原则：什么可以改、什么必须成文

边界类原则处理两处"界线"：一处是免疫的边界（什么不被改），一处是成文的边界（什么必须写下来）。

5.4.1 原则 6：定义与表达分离

语义内容（定义）由模型单方面决定、不受数据影响；反馈只作用于表达形式。

第 4 章已经界定：被免疫的是定义，不是表达。这条原则把这个界定变成一条施工要求 —— 把两层分开处理，不要因为"表达要改"就顺手动了定义。

本项目现状：定义层已确定；表达层为 MVP 版本，会出现难以理解的文言文或抽象描述；"可改"的能力具备但未应用 —— 改起来很快，但模型的正确输出才是重点。

这条原则有一个副作用：表达层粗糙，可能反过来影响体验者的判定 —— 体验者读到难懂的表述，可能把"看不懂"判成"模型不对"。

第 7 条的风险在分流环节（事后归类时混在一起），由"提取内核"挡住，面向阶段二。本条的风险在判定环节 —— 它位于分流的上游，分流挡不住，而且阶段一就在跑。

违反它会怎样：①表达调整悄悄改写定义，污染经旁路进入系统；②表达层粗糙渗入主链数据，使反馈数据里混入本属于表达层的抱怨。

5.4.2 原则 9：判据显性化

判据必须从人因研究的结论落成文字。

判据是验证的标尺。如果标尺只活在体验者的判断里，那么验证不可复核、判定分歧无法归因 —— 两个人给出不同判定时，你无法判断是"标准不一致"还是"这份东西确实处在边界上"。

本项目现状：未成文，但具备落地条件。 这不是一句含糊的自我安慰，而是两条具体事实：

32. 原始材料保留（录音 / 聊天）→ 判据可事后反推成文。 体验者的原话就在语料里，不必重新访谈。"未成文"不等于"不可复现" —— 它只意味着成文的动作被推迟了，而原料完好。
33. 判定者可被回溯重评 → 稳定性可测。这里要修正一处早期的设想：原以为"判定者有多名 → 可以算评分者间一致率"。但第 4 章 4.7 已确认，本项目是个体

化生成、各人各评各的、没有共同评分对象 → 该指标在数学上无从计算。可测的不是"多人之间是否一致"，而是"同一个人隔一段时间后是否给出同样判定"（判定者内稳定性）。

两条合起来，第 9 条的状态从"未达成"变成"有明确改进路径"。

违反它会怎样：判定分歧无法归因到具体条款；数据的可信度无法论证 —— 因为读者无法知道这些判定是按什么标准作出的。

5.5 防护类原则：如何保住判据的独立性

防护类五条是本章最集中、也最有力的一组。它们不是各自独立的建议，而是围绕同一个防守对象组织起来的一套结构。

5.5.1 原则 10：判定者的外部性（被保护的对象）

判定必须由产品的真实体验者给出 —— 不是设计参与者，也不是公司内部测试人员。

这条原则单独列出的理由是：它同时是本文的自我诊断与改进方向。它保住了本文最核心的论据 —— 判据代表的是"人"，不是"设计意图"。外部体验者不了解设计意图，因此他们的判定不是设计方的自我确认。这是一条结构性的反驳：它不靠作者的声明，而靠"谁在判"这个可指认的事实。

违反它会怎样：判定退化为设计方的自我确认 —— 判据自己定、自己判，验证环节失去独立信息来源；"预期来自 Human Factors"变成空话；"自己定标准自己判"的质疑无法反驳。

5.5.2 原则 11：原料留存

当分流规则尚未确定时，先完整留存原始材料（录音 / 选择 / 聊天），使未来的分类成为可能。

这条原则解决的是一个真实困境："分类规则没定"不该成为"不能开工"的理由。 先留原料，通路可以后建。这是前瞻性设计，不是操作习惯。

一条可复用的经验：

渠道的选择决定了原料的可获得性。 本项目用现成渠道（微信）做验证 —— 模型出结果、微信送达、体验者微信反馈"符不符合"、运营对接。于是原始材料天然留存：聊天记录本来就在，录音另有保存。第 7 条所需要的原料，几乎没有额外的采集成本。 换言之，第 11 条在本项目中几乎是免费获得的。若换成一个专门搭建的采集界面，原料的留存反而需要额外的设计与维护。这不是巧合，是选对渠道的结果 —— 对做同类系统的团队，这是一条可直接搬走的经验。

违反它会怎样：原始材料不留 → 想建通路时无据可依，只能重新采集；第 7 条的两条硬约束永远无法被验证；第 9 条（判据反推成文）也一并失去基础。

5.5.3 原则 12：通道中立

当判定经由中介（如运营同事）收集时，中介只做逐条记录：把体验者的回复按 12 个方面记为「符合 / 部分符合 / 不符合」，不改写原话，也不向体验者解释模型的想法。

这条原则针对的是传递环节。本项目中的中介是运营同事 —— 他把体验者的回复收集起来，并在询问时按 12 个方面逐条记为「符合 / 部分符合 / 不符合」，但不改写原话、不归纳出体验者没说的意思，也不向体验者解释模型的想法。

本项目状态：已满足。

违反它会怎样：中介一旦解释或引导（"这个其实是……"）→ 体验者的判定不再纯粹外部 → 第 10 条失效，"判据代表人不代表设计意图"这句核心论据从"结构上成立"退化为"程度上说不清"。

表 5-3　中介（运营同事）的两重角色

阶段	角色	他影响什么	是否影响"外部性"
阶段一（现行）	记录者 —— 收集、记下，并逐条记为固定三值	什么都不影响 （透明通道）	不影响
阶段二（下一步）	归类者 —— 提取内核、分流	只影响"这条算判定还是意见"	不影响 （归类不改变判定内容）

即："外部性"（判定由谁形成）与"分类权"（判定被归到哪一类）是彻底分开的两件事。 前者在现行流程中已经完好；后者仍是下一步的待办。

5.5.4 原则 13：个体化判定

判定必须由输出所指向的那个人本人给出；判定不得跨个体汇总为"对同一对象的评分"。

这条原则由个体化生成这一事实推出（见第 4 章 4.7）：既然输出是为每个人单独生成的，那么判定就只能由那个人本人给出 —— 换任何别人来判，判的都不是同一件东西。

本项目状态：已满足（各人各收一份、各评各的）。

违反它会怎样：①把 8 人的判定当作对同一模型的重复评分 → 会算出"评分者间一致率"这类在本场景下不成立的指标 → 数据被误读；②若改由他人代判 → 判定对象与判定者错位，判定本身失去意义。

5.5.5 原则 14：陈述不引导

模型输出必须以陈述方式给出对当日状态的判断，不得使用引导性、暗示性措辞。

这条原则由"模型只是客观地给出当日状态，没有引导词汇"这一事实推出。

它排除的是一种比巴纳姆效应更隐蔽的自证机制 —— 措辞诱导：

- 巴纳姆效应靠描述模糊 —— 说得足够笼统，人人都能对号入座；
- 措辞诱导靠问法施压 —— "你是不是最近觉得有点累？"即使模型确实说中了，这个问法本身也会人为拉高符合率。

本项目状态：已满足。

违反它会怎样：判定失去区分度，"验证"退化为"模型说什么用户都点头"。注意失败模式的特殊性：这里模型可能并没有做错任何事（它确实说中了），坏结果是判定环节的失效造成的。这也正是它比巴纳姆效应更难察觉的原因。

这条原则可以被审稿人直接复核。输出的形式特征是可观察的 ——

- 可采用的形式：可独立核对的陈述句："你今天的状态是 X"
- 须避免的形式：征求认同的问句："你今天是不是 X？"

在本文的四类原则中，这是唯一一条能用"看一句话的形式"来验证的原则。它的形式证据成本近乎为零。

5.6 原则之间的依赖：谁保护谁

十四条原则不是一张平行的清单。它们之间有明确的依赖与保护关系（表 5-4）。把这张表读一遍，可以看出整套原则的骨架。

表 5-4　原则之间的依赖关系

关系	说明
12 与 14 构成一对，共同保护 10	第 12 条管"传递环节不污染"，第 14 条管"输出环节不诱导"。光有外部的判定者不够 —— 传递不污染、输出不诱导，外部性才算真正落地。
13 与 14 是 10 的两条补充防线	第 13 条管"谁判"（必须是本人），第 14 条管"怎么问"（不许诱导）。三条合起来，判定者的独立性在"人、对象、素材"三个面都被保住
11 是 7 的前提	没有原料，就没有分流的对象。两条应放在一起写
11 同时是 9 的基础	原料在 → 判据可事后反推成文；否则第 9 条无从落地
6 是 3 的前提	定义不受数据改 → 数据只能作用于表达 → 数据的作用范围才是受控的
2 → 3 → 5 是一条链	先判定（2） → 再分流（3） → 且判定须可归因（5）。三者是同一道工序的三个要求
1 → 4 → 8 是同一件事	模型不从数据来（1） → 故价值在模型（4） → 故输出不受使用者扰动（8）

这张表最重要的一行是第一行。 第 12 条与第 14 条各自单独看都只是一条操作规范；并排放在一起看，它们才构成一个完整的防守：一条守住判定的"传入"，一条守住模型的"输出"，中间留给判定者的，是一个没有被任何一方施加影响的空间。

5.7 状态盘点：哪些原则已经在跑

十四条原则的实现程度并不相同。逐条盘点（表 5-5）。

表 5-5　十四条原则的实现状态

状态	原则	说明
已在运行，且有独立确认的事实支撑	10、11、12、13、14	这五条不是建议，是本项目中已经在跑、且能被外部核对的事实。多数方法论论文只能提出原则；本文有五条原则自带实证支撑
已内建于设计	1、2、3、4、5、6、8	本项目即按此设计（第 4 章已逐条对应），但未单独取证——属"设计如此"，不属"已测得"
有明确改进路径	9	当前未成文，但原料在、反推路径明确（见 5.4.2）
目标状态，尚未运行	7	机制与硬约束已定，归类规则未定。

34. 不要把"已内建于设计"写成"已被验证"。 二者的证据强度不同。第 4 章为第 1、4、8 条提供了结构性论证，为第 2、3、5 条提供了流程事实，但这些都不是独立的测量。
35. 第 7 条与其余各条的区分必须贯彻全篇。 它是本文唯一一条"尚未运行"的原则，也是唯一一处"设想"。把设想写成事实，是本文最容易被指出的问题。

5.8 本章小结

本章把第 4 章的结构判断落成了十四条可操作的原则，并给出四类分组：

- 结构类（1、4、8） 定住模型的位置；
- 流程类（2、3、5、7） 规定数据如何产生；
- 边界类（6、9） 划清什么可改、什么必须成文；
- 防护类（10、11、12、13、14） 保住判据的独立性。

第一，防护类五条是成套的，不是零散的。 它们围绕第 10 条（判定者的外部性）组织成一个结构：第 11 条备好原料，第 12 条守住传递，第 13 条锁定判定者，第 14 条管住问法。"外部性"不是一句声明，而是四条可检查的操作共同支撑起来的事实。

第二，第 9 条与第 10 条同时是本文的自我诊断与改进方向。 它们明确写出了两处当前未达成的状态（判据未成文、判据须靠外部性成立），同时给出了明

确的改进路径。写好了是亮点 —— 因为它们恰好说明这套方法论下一步该往哪走；回避了就是硬伤。

第 6 章　可检验命题

与第 4、5 章相同：因此本章的一切检验都只落在链条的行为上 —— 模型收到什么、产出什么、谁来判、数据如何沉淀。没有一条检验需要读取模型内部指标。

6.1 认输条件：先声明什么情况下本文是错的

- 本文主张：这条路径可行；以模型为出发点是可行的。
- 本文不主张：这条路径更优（更快 / 更省 / 更准 / 返工更少）。
- 举证标准：主张"可行" → 举证标准是存在性证明，不需要对照组；只有主张"更优"才需要对照组与返工实测。

若有人拿"没有对照组"来质疑，那个质疑的前提（本文主张更优）并不成立 —— 本文从未这样主张过。

本文的可证伪性不建立在"我们预计会看到什么"上，而建立在两条不变式上。作者明确承诺：若这两条不变式中的任何一条被打破，本文的路径主张即被推翻。

表 6-1　认输条件（作者给出）

编号	认输条件	它打破的不变式	被打掉的命题
a	模型随数据改变	① 数据触不到模型 / 定义	P1
c	定义层出现数据回流	① 数据触不到模型 / 定义	P3
d	使用者能影响模型输出	② 使用者触不到模型输出	P7

a 与 c 是同一不变式在两处的检验 —— 一处检验模型本身，一处检验语料库的定义层。因此三条认输条件实际上只归约为两条不变式：

不变式一：数据触不到模型，也触不到定义。 不变式二：使用者触不到模型输出。

这两条不变式正是第 4 章那条"单向、结构上封闭"的链在可检验层面的等价表述。它们的好处是可指认：不需要测量任何内部量，只需要观察"模型的行为有

没有随数据变化"、"使用者的行为有没有改变输出"。这正是黑箱约束下唯一可用的检验形态。

6.1.1 一个未解的子项，以及本文如何回应它

作者在给出认输条件时，还提出了第三个候选子项（记作 b）—— 大意是"验证筛不出东西"。但作者本人判定它为伪命题，并明确表示暂不知如何作答。

本文对这一未解子项的处理方式是正面回应，而不是回避：把它转化为一条可检验的命题（P8，验证环节的有效性），用阳性对照来回答 —— 如果验证环节确实在做事，那么注入一个已知缺陷，它应该被判为"不符合"；如果连已知缺陷都筛不出来，"验证在做事"这句话就没有依据。

它是本章从"未解"中取得的最实在的收获。

6.2 命题清单

P13 已撤回，不在清单内（原因见 6.6）。P9 已拆为 P9a / P9b 两条子命题。故本表共 15 行，对应 14 条命题编号。

表 6-2　命题清单（P1 – P15）

编号	命题	检验它要观察到什么	什么结果会推翻它	所需数据
P1	免疫命题 —— 模型的行为不随运行数据的规模与质量而变化	数据量增长后模型行为不变	模型随数据改变（认输条件 a）	模型行为的历史记录 [待补]
P2	判据命题 —— 判定标准源于 Human Factors、但经由外部体验者的判断而生效，非外部业务指标	判据可追溯到人因研究的结论	判据实际来自业务指标（如留存、满意度评分）	判据成文材料 [待补]
P3	污染命题 —— 观察期内，定义层的成簇污染案例为零	观察期内，定义层未出现成簇污染	定义层出现数据回流 （认输条件 c）	定义层变更记录 [待补]
P4	依赖命题 —— 链条下游的判据	逐环可指认其由模型派生	某一环另有独立来源	结构性论证（第 4 章）

	与数据结构均可由模型单向派生			
P5	表达派生命题 —— 表达层完全由模型派生；移除模型后它既无内容也无功能	表达层无自有内容	表达层存在独立于模型的内容源	结构性论证（第 4 章 4.4）
P6	表达可修正命题 —— 体验者的意见可以改变表达形式，但不改变定义	表达层随意见变化、定义层不变	意见改动了定义	表达层变更记录 [待补]
P7	通路隔离命题 —— 主链与表达修正通路的作用对象之间无交叉影响	两条通路的作用对象互不重叠	使用者能影响模型输出 （认输条件 d）	第 4 章 4.5 的流程事实
P8	闸门有效性命题 —— 验证环节对已知缺陷具备识别力	阳性对照：注入已知缺陷，应判"不符合"； 阴性对照：注入已知正确，不应被误判	已知缺陷未被识别 → 验证环节不做事	需主动注入 [待补：是否可做]
P9a	个体符合率 （描述性） —— 每位判定者对"为其生成的"报告的符合率可被统计	得到 8 条个体链各自的符合率	—— 这是描述性统计，不是信度指标	反馈数据（已在手上）
P9b	判定者内稳定性（回溯性） —— 把历史输出隔一段时间再给同一位判定者看，判定不变	同一位判定者对同一份历史输出给出同样判定	重评结果系统性改变 → 判定不稳定	须主动补做 （同一输出不会自然重复）
P10	判据来源命题 —— 判定不依赖设计意图的知识	盲预测：了解设计意图者预测"该体验者会不会说符合"，与实际判定比对	设计方能准确预测 → 判据的根在设计意图里	历史输出（已在手上）
P11	双通道分流命题 —— 判定与意见可被稳定分开	两名独立编码者按拟定规则分类， 一致率高	一致率低 → 两者在表达中本就交织，规则需细化	留存的原始材料（已在手上）

P12	判定纯度命题 —— 体验者的判定不受表述质量的影响	对漏洞点做内容编码，"表达类抱怨"占比低	占比高 → 判定被表述质量污染	漏洞点聊天记录（已在手上）
P14	区分度命题 —— 判定具有区分度，不是巴纳姆效应	错配对照：把 A 的报告给 B 看，B 的一致率显著下降	B 也普遍说"一致" → 判定受巴纳姆效应驱动	留存报告（已在手上）
P15	信息增益命题 —— 产出不是输入的复述	输出端信息量远超输入端；输出与初始值的重合比例低	输出基本可由初始值推出 → 产出主要是复述	初始值 + 输出序列（已在手上）

6.2.1 三条命题值得单独说明

P9a 是描述性统计（每个人自己的符合率是多少），P9b 是信度检验（同一个人的判定稳不稳）。把 P9a 当作信度指标使用，是本章最容易犯的错误 —— 一个稳定的高符合率和一个不稳定的高符合率，在 P9a 上看起来完全一样，只有 P9b 能区分。

P8 是本章唯一的对照检验。 其余命题都是"观察已有材料"，只有 P8 需要主动注入。它的代价高一些，但它回答的是那个未解的疑虑（6.1.1），价值也最高。

P14 与 P15 是互补的一对，必须一起读。 它们回答的是同一个问题的两半：

P14 检验"判定有没有区分度"；P15 检验"产出有没有独立来源"。 两条合起来，才完整回答"符合"是不是真的。

只有 P14 通过、P15 也通过，"模型说中了他"这句话才同时具备两个必要条件：判定能分辨（P14），且被分辨的东西确实来自模型而非复述（P15）。缺任何一条，另一个的结论都会被架空。

6.3 七项可实操的检验设计

十四条命题中，七项可以真正动手做，且大部分所需材料已经在手上。本节按成本从低到高展开（表 6-3）。

表 6-3　七项实证设计：成本与产出

序	设计	检验	成本	材料状态	两种结果是

					否都是收获
1	漏洞点内容编码	P12	最低	已在手上	是
2	错配对照	P14	极低	已在手上	是
3	个体符合率统计	P9a	低	已在手上	—— 描述性
4	判定者内稳定性重评	P9b	中（须补做）	需主动抽取	是
5	分流可行性检验	P11	中（需先拟规则）	已在手上	是
6	判据来源盲预测	P10	中	已在手上	是
7	信息增益与重合度编码	P15	中	已在手上	是
（另）	闸门对照	P8	高（需注入）	需主动构造	是

6.3.1 第一项：漏洞点内容编码（检验 P12）

要回答的问题：我们唯一的数据干不干净？

背景：语料库表达层是 MVP 版本，会出现难以理解的文言文或抽象描述。体验者在判定时确实会读到难懂的表述，于是"看不懂"有可能被判成"模型不对"。

做法：对现有反馈数据中的漏洞点做内容编码 —— 漏洞点以聊天记录形式存在，统计"表达类抱怨"（看不懂 / 表述奇怪 / 太抽象）的占比。

两种结果的解读（表 6-4）：

表 6-4　P12 的两种结果

结果	解读
占比低	正面证据 —— 体验者能区分"模型不对"与"表述难懂"， 主链数据是干净的
占比高	必须如实报告 —— 写成"表达层待修对主链数据纯度的已知影响"

这是印象，不是实测数字（实测见 7.3.1）。

为什么把它排第一：两种结果都是收获，而且不需要新采集数据 —— 它是本文第一个可以立刻拿出来的实证结果。

6.3.2 第二项：错配对照（检验 P14）

要回答的问题：判定有没有区分度？

背景：本项目的输出是为每个人单独生成的，且模型独立推演。这必然招来一个质疑 ——

"你给每个人一份看起来像在说他的话，他当然说符合。"（巴纳姆效应，[16] Forer 1949）

这是对个体化验证最强的通用反驳，必须正面回答。

做法：把 A 的报告给 B 看，问 B"这是否和你今天的状态一致"（错配对照 / mismatched-report control）。

这个设计因为判定的问法已确认而变得异常干净：原判定问的是"符不符合，以及是否和你今天的状态一致" —— 问的是"你今天的状态"，而递过去的报告是 A 的。因此若 B 也说一致，那就是真的巴纳姆效应，排除了"问法不力"这一解释。

两种结果的解读：

- B 的一致率显著下降 → 判定有区分度，"看起来像"的质疑被反驳；

36. 描述确实模糊到人人都能对号入座（真正的巴纳姆效应）；
37. 问法或措辞本身有诱导性。

本文已排除第 ② 种：模型只作客观陈述、无引导词汇，问法也是"是否和你今天的状态一致"这类可证伪的比对。→ 故若 B 说一致，更可能指向第 ① 种。这一区分让 P14 的结论更干净。

成本极低：报告是留存的，不需要新采集数据。

6.3.3 第三项：个体符合率统计（检验 P9a）

要回答的问题：每个人自己的符合率是多少？

做法：统计每一位判定者对"为其生成的"报告的符合率 → 得到 8 条个体链各自的符合率。

这是描述性统计，不是信度指标。第 7 章应按"逐案呈现 + 跨案汇总"来写，而不是按"评分者间"来写 —— 因为 8 人不是 8 名评分者，而是 8 条独立个案。

6.3.4 第四项：判定者内稳定性重评（检验 P9b）

要回答的问题：同一个人隔一段时间后，会不会给出同样的判定？

做法：抽 1–2 位判定者、各 5–10 份历史输出，隔一段时间重评，看是否仍给同样判定（具体规模 [待补]）。

这是本场景下唯一可行的信度检验。 它之所以必须做，是因为"符合 / 不符合"这个二分没有第二道把关（判定由体验者本人直接给出，运营只把回复逐条记录为固定取值，不对判定本身作独立判断）。而这道缺口不能靠"体验者之间是否一致"来兜底 —— 原因见 6.4。

6.3.5 第五项：分流可行性检验（检验 P11）

要回答的问题：判定与意见能不能被稳定分开？

它检验的是"能不能分得开"。

做法：从留存的原始材料中抽一批，由两名独立编码者按拟定规则把"判定"与"意见"分开，计算一致率。

- 一致率高 → 分流可行、通路可建；
- 一致率低 → 两者在体验者表达中本就交织，规则需细化（这本身是发现）。

为什么这一步必须在建通路之前做：它直接决定第 5 章第 7 条原则能否落地。若不做，第 7 条就只是一个未经验证的设想。

前置条件：需要先拟一份归类规则（[待补：规则草案]）。

6.3.6 第六项：判据来源盲预测（检验 P10）

要回答的问题：判定依赖设计意图的知识吗？

这是本文最干净、最有力的一项检验 —— 它正面回答"自己定标准、自己判自己"这一循环论证的质疑。

前提已被确认：运营不向体验者解释模型的想法 → "体验者不了解设计意图"是真的 → 这个对比才真正有效。若运营曾解释过，本检验会因前提被污染而失效。

做法：让了解设计意图者（设计方 1–2 人）对若干条历史输出作盲预测 —— "这位体验者会不会说符合"，再与本人实际判定比对。

- 预测不准 → 判据不在设计意图里、而在"人"里 → 循环论证的质疑不成立；

但本项目是个体化生成的 —— 没有"同一批"，原设计不可行。改为盲预测后，检验的对象从"一致性"变成"预测力"：

一致性容易被"反正你们想法一样"这类理由消解；预测力不能。 预测对不对是硬事实。

成本：只需设计方对若干条历史输出作盲预测即可，材料已在手上。

6.3.7 第七项：信息增益与重合度编码（检验 P15）

要回答的问题：产出是输入的复述吗？

背景：用户主动输入是一次性的（初始值），此后不再提供；而模型每天输出都不一样。这个"输入枯竭而输出持续"的结构，本身就是一条证据（见第 4 章 4.8.1）。P15 要把这条证据量化。

做法（两步，粗粒度）：

38. 粗粒度信息量对比：估算初始输入的信息量（篇幅 / 可提取的命题数）与输出序列的信息量 → 若输出远超输入，则产出不可能主要来自输入；
39. 内容编码：统计输出中与初始值重合的比例 —— 重合部分仍可能是复述，不重合的部分即模型的独立贡献。

完全排除锚定（anchoring）是不可能的。

本文只能给出"产出超出初始值可推范围"的证据，不得声称已证明模型完全独立。这一限定不能省略 —— 省略了，就等于把一个"部分排除"写成"完全排除"。

6.4 一条应写进正文的方法论要点：评分者间一致率在本场景下不适用

本节单独列出，因为它是本文可以被同行直接引用的一处贡献，而不是一处需要遮掩的缺陷。

问题：判定者有 8 人。在常规的验证与确认场景里，8 名评分者意味着可以计算评分者间一致率，用来衡量判定的可靠性。

但本项目不能。 原因是本项目采用个体化生成：模型为每个人单独生成结果，各人各收一份、各评各的 —— 每个判定者面对的是为他本人定制的那一份。

一致率的前提是共同评分对象（common stimuli）。本项目不存在共同对象 —— 因此该指标在数学上无从计算。

在个体化生成系统中，经典的评分者间一致率不适用。

随着个体化生成在推荐、健康报告、个性化助手等场景中变得常见，这个陷阱会被越来越多地踩到。本文明确写出这一点并给出替代方案，这本身就是一个可被同行引用的贡献。

替代方案：判定者内稳定性（intra-rater reliability / test–retest） —— 即 P9b。

6.4.1 这处替代方案的既有归属：SCD / N-of-1

2026-10-08 补入。本文的验证形态（每人各评各的、无共同评分对象）在方法学上落在既有的「单被试设计（single-case design, SCD）/ N-of-1 trial」框架内 —— 该框架以单个个体为分析单位，其设计前提正是"不把跨个体的观测汇总为对同一对象的重复测量"。

文献	内容	作用
[18] Vohra, S., et al. (2015). CONSORT extension for reporting N-of-1 trials (CENT) 2015 Statement. BMJ, 350 , h1738.	N-of-1 试验的报告规范	说明该框架有成文的报告标准
[19] Tate, R. L., et al. (2016). The Single-Case Reporting Guideline In BEhavioural Interventions (SCRIBE) 2016 Statement. American Journal of Occupational Therapy, 70 (4), 544–555.	单被试设计的报告规范	

40. 正面的：本文说"评分者间一致率不适用"时，替代方案不是临时发明的 —— 它属于一个有长期积累、并有正式报告规范的方法学传统。这使那条要点从"辩解"变成"定位"。
41. 故本文可以说"本文把 SCD / N-of-1 的应用推进到一个新对象上"，不可以说"本文已在该对象上建立完整方法学"（第 8 章 8.5 第 9 条）。

它说明本文的验证形态有方法学归属，不说明本文的结论已被该传统支持 —— 本文的结论仍只由第 3–7 章自己的证据支撑。

6.4.2 可靠性由三条共同保证

既然一致率算不出来，"符合 / 不符合"这个二分没有第二道把关这一代价就必须正面承认。但不能据此说"可靠性完全取决于体验者之间是否一致" —— 那句话的前提在本场景下不成立。

本场景下，可靠性由三条共同保证：

42. 每位判定者自身认知的稳定性（→ P9b 检验）；
43. 判定确实由本人作出（已确认）；
44. 传递环节不污染（第 5 章第 12 条原则，已确认）。

凡涉及"信度"的位置，一律用判定者内稳定性。

6.5 命题、原则与结构事实的追溯

本章的命题不是凭空提出的。每条命题都可以回溯到第 4 章的一处结构事实或第 5 章的一条设计原则（表 6-5）。这张表的作用是：让读者能够检查本文有没有提出任何一条与正文论证无关的命题。

表 6-5　命题的追溯

命题	追溯到第 4 章	追溯到第 5 章
P1 免疫	4.10 免疫边界	原则 1 模型先行
P2 判据	4.2 双链结构、4.3.4 判据的形态	原则 9 判据显性化
P3 污染	4.10 免疫边界	原则 6 定义与表达分离
P4 依赖	4.11 模型是唯一源头	原则 4 模型承载价值
P5 表达派生	4.4 系统构成	原则 4 模型承载价值

P6 表达可修正	4.4.3 语料库两层	原则 6 定义与表达分离
P7 通路隔离	4.5 同一人群、双通道	原则 7 双通道分流
P8 闸门有效	4.3.1 验证机制	原则 2 验证前置、原则 5 反馈可解释
P9a / P9b	4.7 个体化生成	原则 13 个体化判定
P10 判据来源	4.2 「人 → 人」闭环、4.3.2 外部性	原则 10 判定者的外部性
P11 分流可行	4.5.2 分流是工序	原则 7、原则 11 原料留存
P12 判定纯度	4.4.4 表达层对主链的影响	原则 6 定义与表达分离
P14 区分度	4.9 三层支撑与四重排除	原则 14 陈述不引导
P15 信息增益	4.8.1 验证的信息来源	原则 1 模型先行

本文最有价值的检验，恰恰是从最不体面的地方长出来的。

6.6 未列入清单的命题：P13 的撤回及其后果

本文曾提出过一条 P13（编码可复核性命题），现已撤回。记录在此，因为它留下了一条重要的后果。

原设想：判定以自由文本（聊天记录）形式存在 → 统计"符合 / 不符合"必然要先把聊天读成二分 → 于是存在一次解释性编码 → 因此需要检验这次编码的可复核性。

撤回原因：这个前提与实际不符。判定确由内测体验者本人直接给出 —— 运营在询问时把回复按 12 个方面逐条记为「符合 / 部分符合 / 不符合」，三个取值都由体验者给出，日级「是否符合」再由 12 个方面按 ≥60% 的固定规则合成。也就是说，从回复到取值确实有一次记录，但它是当场按固定取值进行的，不是事后对自由文本的解释性编码。原命题设想的"事后由第三方读聊天、再读出二分"这一形态不存在，故 P13 按原设定无从检验。这也同时撤回了一个更早的推论 —— 那个推论曾认为"分类权问题在阶段一就已经生效"；撤回后，分类权问题回归"面向阶段二"。

但撤回留下了一条后果，必须承认：

"符合 / 不符合"这个二分没有第二道把关。

而这不能靠"体验者之间是否一致"来兜底（一致率根本算不出，见 6.4）→可靠性改由三条共同保证（P9b + 判定确由本人作出 + 传递不污染）。

P13 的撤回是本文的一处净损失，但也是必要的自我修正。保留一条前提不成立的命题，代价比撤回它更大。

6.7 本章小结

本章给出了：

- 两条不变式与三条认输条件 —— 本文的可证伪性底线；
- 十四条命题（P1–P12、P14、P15），其中 P9 拆为 P9a / P9b，共 15 行；
- 七项可实操的检验设计，其中五项的材料已经在手上；
- 一条可被同行引用的方法论要点 —— 个体化生成系统中评分者间一致率不适用。

第一，本章的检验几乎全部不需要新采集数据。这是本项目的一个结构性便利：因为渠道是现成渠道（微信），原始材料天然留存；因为模型每天自运行，历史输出已经积累。七项设计中，只有 P8（闸门对照）需要主动构造材料，P9b 需要主动抽取历史输出，其余五项的材料都已在手上。

第二，本章的检验不依赖模型内部信息。全部七项检验都只落在链条行为上 —— 谁判的、判了什么、跟什么比、产出有多少。这是黑箱约束下的必然选择，但结果反而使本文的检验设计对同行更可用：任何做同类系统的团队都能照做，不需要开放模型内部。

第三，本文最有价值的检验，来自本文最不体面的地方。表达层未修（P12）、措辞可能诱导（P14）、初始值可能锚定（P15）—— 这三处都是本文主动写出来的弱点，而七项检验中有三项正对着它们。把弱点转成检验，比把弱点藏起来更有说服力。

第 7 章　案例研究：产品数据作为证据

本章的全部证据都只落在链条行为上 —— 模型收到什么、产出什么、谁来判、判了什么、数据如何沉淀。没有一项证据来自模型内部指标。

7.1 案例选择与研究设计

案例的性质：本文案例是一款具身机器人产品，其实际使用场景为家庭 —— 即一款面向家庭场景的具身机器人。本文的领域定位是「具身机器人」（大类）；家庭场景是该案例的具体设定，不是本文的领域限定。

7.1.1 为什么是这一个案例

本文采用的是目的性抽样：案例不是因为"有代表性"而被选中，而是因为它恰好同时具备本文论证所需的全部条件。这些条件有四条，缺一条本文的核心论证就无法落地：

#	条件	它对本文的作用
1	人因驱动 —— 模型由对人的研究设计而来，不来自数据	使"模型不从数据来"成为事实，而非主张
2	模型先行 —— 模型在链条最上游，下游由它派生	使"模型最重要"成为可指认的结构关系
3	模型每日自运行 —— 输出按日产生，使用者无法影响	使数据有稳定的产生节拍，且排除使用者扰动
4	由外界内测体验者判定	

第 4 条需要单独说明。判定者是产品的真实体验者，不是公司内部测试人员，也不是设计参与者。他们不了解设计意图。正因为如此，他们的判定不是设计方的自我确认 —— 这使"判据代表的是'人'，而不是'设计意图'"成为一个可指认的事实，而不是作者的声明。

这一条是整个案例的支点。 若换成一个由内部测试人员打分的案例，本文最核心的论据（对"自己定标准、自己判自己"这一循环论证的结构性反驳）将无法成立。案例选择因此不是随意的 —— 它是论证的一部分。

7.1.2 研究问题

研究问题由第 6 章的命题转化而来（表 7-1）。RQ9 已撤回（它预设的"事后从聊天读出符合 / 不符合"这一形态不存在），不在清单内。

表 7-1　研究问题清单

RQ	研究问题	对应命题	状态
RQ1	在「模型 → 验证 → 数据」路径下，模型的输出是否随运行数据的规模与质量变化？	P1	待观察 [待补]
RQ2	验证环节能否识别已知缺陷？	P8	待做（需注入）
RQ3	反馈数据中是否出现定义层的污染案例？	P3	待观察 [待补]
RQ4a	每位判定者对"为其生成的"报告给出的个体符合率是多少？	P9a	现在就能做 （描述性）
RQ4b	同一位判定者对同一份历史输出重复判定时，是否稳定？	P9b	
RQ5	判据是否自证？ —— 让了解设计意图者盲预测"某位体验者会不会说符合"，与实际判定比对	P10	现在就能做
RQ6	使用者的反馈是否影响到模型输出或反馈数据的统计量？	P7	待观察 [待补]
RQ7	留存的原始材料中的"判定"与"意见"，能否被稳定地分开？	P11	现在就能做 （回溯性）
RQ8	现有漏洞点中，"表达类抱怨"占多大比例？	P12	已做（见 7.3.1）
RQ10	判定具有区分度吗？—— 把 A 的报告给 B 看，问 B"这是否和你今天的状态一致"，B 的一致率是否显著下降？	P14	现在就能做

RQ11	产出是输入的复述吗？—— 输出端信息量是否远超一次性输入？重合比例多少？	P15	现在就能做
RQ12	判定的参照物独立于模型吗？—— 体验者判断"我今天的状态"时，依据是内省还是模型描述？	——	已确认（大多数是内省），边界待补

表中"现在就能做"的六项，是本章的重点。它们不需要新采集任何数据 —— 材料已经在手上。

7.1.3 设计的性质与它带来的边界

45. 单案例、单产品、单团队 —— 结论限定在"这一类研发路径"，不外推到"所有具身机器人的研发"。
46. 无对照组 —— 本项目从未运行过传统路径，因此没有返工实测、没有平行对照。这一点直接决定了本文的主张强度：本文不主张"更快 / 更省"，只主张"污染在结构上进不来"。这不是缺陷，而是与主张范围相匹配（第 3 章 3.6.3：本文主张"可行"、不主张"更优" → 举证标准是存在性证明、不需要对照组）。
47. 探索性小样本 —— 判定者 8 人，招募方式为网上发帖、对产品感兴趣者自愿报名 → 属自愿样本 / 便利抽样，存在自选偏差（可能偏向技术爱好者 / 早期采用者），未必代表普通用户。

结论限定在"该产品所服务的这一类自愿内测用户"；8 人用于探索与描述，不做统计推断。

但这里也有一点可以正面写：报名者是真正兴趣驱动的（不是朋友帮忙、不是内部人员）→ 外部性更实在。他们不是被指派来打分的人。

7.2 数据的来源、形态与收集清单

7.2.1 数据的来源与载体

反馈数据来自验证环节。其来源与载体已确认：

项	内容

判定由谁给出	内测体验者本人直接给出（依据是模型给出的结论）—— 三个取值都由体验者给出，运营只逐条记录，不是事后读聊天解读得出的
判定的载体	聊天记录（自然语言文本）—— "不符合的点"就是聊天里的一段话
另有	录音
渠道	统一为微信：模型出结果 → 微信送达 → 体验者微信反馈"符不符合" → 运营对接

由"判定由本人直接给出"这一事实，推出一个重要性质：

体验者的回复是一手数据；12 个方面是它在询问时被逐条记录的结果，日级「是否符合」再由 12 个方面按 ⩾60% 合成。被派生的只有统计量。

7.2.2 两层结构：原始层与派生层

反馈数据分两层，本章的分析动作要分别对待（表 7-2）。

表 7-2　反馈数据的两层结构

层	内容	性质
原始层	判定（符合 / 不符合）+ "不符合的点"（聊天记录）+ 录音	证据 —— 可回溯、可反推判据、可做内容编码
派生层	统计量（有效反馈数 / 漏洞点数 / 通过率 / 个体符合率 / 类型分布）	产物 —— 由原始层算出

这一区分决定了本章多处分析的做法：凡涉及"判据反推"、"表达类抱怨占比"、"错配对照"的分析，都作用在原始层上；凡涉及"符合率"、"通过率"的呈现，都作用在派生层上。

一条可复用的经验：由于渠道是现成渠道（微信），原始材料天然留存 —— 聊天记录本来就在，录音另有保存。渠道的选择决定了原料的可获得性。 本章之所以有六个动作"现在就能做"，直接得益于这一点。

7.2.3 数据收集清单

已确认项与待补项混排，便于逐项核对。标 [待补] 处由作者补齐。

表 7-3　数据收集清单

项	内容	状态
运行时长 / 时间窗	2026-08-28 – 2026-09-13（共 17 天）	已定
判定者人数与来源	8 人；网上发帖、对产品感兴趣者自愿报名	已定
是否存在评分重叠	否 —— 各人各评各的、无共同评分对象	已定
每人各自的判定条数	16 / 16 / 17 / 17 / 16 / 16 / 15 / 15（共 128 客户日，面板不平衡）	已定
模型生成报告的输入	用户一次性提供初始值（自我陈述），此后不再提供；模型独立推演 （行为 / 状态 / 交互 —— 用户未主动告知）； 输出每天不同	已定
被动观测是否持续	[待补] —— 行为 / 状态 / 交互的观测是持续流入还是一次性的？	待补
判定的问法	"符不符合 + 是否和你今天状态一致" → 属"对不对"型问法；参照物 = 体验者自己今天的实际状态	已定
参照物的独立性	大多数是内省；模型只客观给出当日状态、无引导词汇	
"大多数"的边界	[待补] —— 非内省情形大致占比多少？	待补
判定粒度	逐日 → 天然形成时间序列；但跨日判的是不同输出， 不是严格重测	已定
初始值的形态与信息量	[待补] —— 用户填了什么、篇幅多大（P15 的分母）	待补
模型每日产出条数	每张卡 12 个方面	已定
判定总条数	128 个客户日（逐方面展开为 1536 个判定点）	已定
有效反馈数 / 漏洞点数	日级 128 / 0；方面级 1503（符合 1481 + 部分符合 22）/ 33	已定
判定通过率	日级 100%（128/128）；方面级 97.14%（计权）、96.42%（严格）	已定

个体符合率（P9a）	8 条：0.872 – 0.995，中位数 0.982（逐条见表 7-6）	已定（描述性）
判定者内稳定性（P9b）	待做 —— 抽 1–2 位判定者、各 5–10 份历史输出重评（规模 [待补]）	待做
评分者间一致率	不适用 —— 无共同评分对象， 在数学上无从计算	作废
漏洞点类型分布	已记归因 12 条，全部为「信息差 / 理解不同」；33 条不符合中 21 条未记归因	已定
表达类抱怨占比（P12）	0%（0/27，严格定义）／7.4%（2/27，含两例边界）	已定
错配对照数据（P14）	待做 —— 把 A 的报告给 B 看，记录 B 的判定	待做
成簇污染案例数	0（观察期内未见）	已定
语料库规模 / 表达修正频次	[待补]	待补
原始材料（录音 / 选择 / 聊天）	已确认保留 —— 待补： 脱敏方式、知情同意、保存期限	细节待补
判定与意见的分流记录	尚不存在 （分流未运行） —— 改为产出： 两名编码者的独立分类结果与一致率	待做
判据来源对照数据（P10）	待做 —— 了解设计意图者对若干条历史输出作盲预测，与本人实际判定比对	待做

7.3 九个分析动作

本章的分析动作共九个，按成本从低到高排列（表 7-4）。

表 7-4　九个分析动作（按成本排序）

序	动作	检验	成本	材料状态
1	漏洞点内容编码	P12 / RQ8	最低	已在手上
2	错配对照	P14 / RQ10	极低	已在手上
3	个体符合率统计	P9a / RQ4a	低	已在手上
4	判定者内稳定性重评	P9b / RQ4b	中（须补做）	需主动抽取
5	分流可行性检验	P11 / RQ7	中（需先拟规则）	已在手上

6	判定留痕	——	中（须改变流程）	待新增
7	判据来源盲预测	P10 / RQ5	中	已在手上
8	信息增益与重合度编码	P15 / RQ11	中	已在手上
9	输出形式复核	第 14 条原则	近乎为零	已在手上

7.3.1 动作一：漏洞点内容编码（P12 / RQ8）

要回答：我们唯一的数据干不干净？

做法：对现有漏洞点做内容编码 —— 漏洞点以聊天记录形式存在，统计"表达类抱怨"（看不懂 / 表述奇怪 / 太抽象）的占比。

两种结果的解读：

结果	解读
占比低	正面证据 —— 体验者能区分"模型不对"与"表述难懂"， 主链数据是干净的
占比高	必须如实报告 —— 写成"表达层待修对主链数据纯度的已知影响"

实测结果如下。

"表达类抱怨"占比 = 0%（严格定义；0/27 个留有聊天记录的漏洞点，另 6 个无记录）/ 7.4%（含两例边界情形；2/27）；把口径放宽到全部 122 条留存反馈记录，出现"表述/呈现类困惑"的也仅 1 条（0.8%），且该条未产生"不符合"。两例边界情形分别是：一例是送达时序造成的日期误解（体验者问「这是昨天的吗」），一例是体验者自述「擦边球」的内容边界模糊；二者抱怨的都不是「看不懂 / 表述奇怪 / 太抽象」，按严格定义不计入。两种口径下"表达类抱怨不构成主要漏洞类型"的方向一致。

7.3.2 动作二：错配对照（P14 / RQ10）

要回答：判定有没有区分度？

做法：把 A 的报告给 B 看，问 B"这是否和你今天的状态一致"。

这个设计因判定的问法已确认而异常干净：原判定问的是"你今天的状态"，而递过去的报告是 A 的。因此若 B 也说一致，那就是真的巴纳姆效应，排除了"问法不力"这一解释。

两种结果的解读：

- B 的一致率显著下降 → 判定有区分度，"看起来像在说这个人"的质疑被反驳；

②问法或措辞本身有诱导性。本文已排除第 ② 种（模型无引导词汇、问法为可证伪的比对）→ 故若 B 说一致，更可能指向第 ① 种。这一区分让 P14 的结论更干净。

结果占位：[待补：B 组一致率 = ___%，对照 A 组 = ___%]

7.3.3 动作三：个体符合率统计（P9a / RQ4a）

要回答：每个人自己的符合率是多少？

做法：统计每一位判定者对"为其生成的"报告的符合率 → 得到 8 条个体链各自的符合率。

这是描述性统计，不是信度指标。一个稳定的高符合率和一个不稳定的高符合率，在 P9a 上看起来完全一样 —— 只有 P9b 能区分。把 P9a 当作信度指标使用，是本章最容易犯的错误。

呈现方式：按"逐案呈现 + 跨案汇总"来写，而不是按"评分者间"来写 —— 因为 8 人不是 8 名评分者，而是 8 条独立个案。

结果占位：见表 7-6。

7.3.4 动作四：判定者内稳定性重评（P9b / RQ4b）

要回答：同一个人隔一段时间后，会不会给出同样的判定？

做法：抽 1–2 位判定者、各 5–10 份历史输出，隔一段时间重评，看是否仍给同样判定（具体规模 [待补]）。

这是本场景下唯一可行的信度检验。 它之所以必须做，是因为"符合 / 不符合"这个二分没有第二道把关；而这道缺口不能靠"体验者之间是否一致"来兜底 —— 一致率在本场景下根本算不出（见 7.3 引言与 7.4.4）。

结果占位：[待补：重评一致率 = ___%（n = ___）]

7.3.5 动作五：分流可行性检验（P11 / RQ7）

要回答：判定与意见能不能被稳定分开？

它检验的是"能不能分得开"。

做法：从留存的原始材料中抽一批，由两名独立编码者按拟定规则把"判定"与"意见"分开，计算一致率。

- 一致率高 → 分流可行、通路可建；
- 一致率低 → 两者在体验者表达中本就交织，规则需细化（这本身是发现）。

这是"建通路之前"的可行性检验，直接决定第 5 章第 7 条原则能否落地。若不做，第 7 条就只是一个未经验证的设想。

前置条件：需先拟一份归类规则 [待补：规则草案]。

结果占位：[待补：两名编码者一致率 = ___%（n = ___）；无法归类的条目比例 = ___%]

7.3.6 动作六：判定留痕

要回答：判定标准有没有随时间漂移？

做法：请体验者在每次判定时补一句理由。事后可抽样检查标准是否漂移。

结果占位：[待补：留痕覆盖率 = ___%]

7.3.7 动作七：判据来源盲预测（P10 / RQ5）

要回答：判定依赖设计意图的知识吗？

这是本文最干净、最有力的一项检验 —— 它正面回答"自己定标准、自己判自己"这一循环论证的质疑。

前提已被确认：运营不向体验者解释模型的想法 → "体验者不了解设计意图"是真的 → 这个对比才真正有效。

做法：让了解设计意图者（设计方 1–2 人）对若干条历史输出作盲预测 —— "这位体验者会不会说符合"，再与本人实际判定比对。

- 预测不准 → 判据不在设计意图里、而在"人"里 → 循环论证的质疑不成立；

但本项目是个体化生成的 —— 没有"同一批"，原设计不可行。改为盲预测后，检验对象从"一致性"变成"预测力"：一致性容易被"反正你们想法一样"消解；预测力不能 —— 预测对不对是硬事实。

结果占位：[待补：盲预测命中率 = ___%（n = ___）]

7.3.8 动作八：信息增益与重合度编码（P15 / RQ11）

要回答：产出是输入的复述吗？

做法（两步，粗粒度）：

48. 粗粒度信息量对比：估算初始输入的信息量（篇幅 / 可提取的命题数）与输出序列的信息量 → 若输出远超输入，则产出不可能主要来自输入；
49. 内容编码：统计输出中与初始值重合的比例 —— 重合部分仍可能是复述，不重合的部分即模型的独立贡献。

完全排除锚定（anchoring）是不可能的。

本文只能给出"产出超出初始值可推范围"的证据，不得声称已证明模型完全独立。这一限定不能省略 —— 省略了，就等于把一个"部分排除"写成"完全排除"。

结果占位：[待补：初始值信息量 = ___；输出序列信息量 = ___；重合比例 = ___%]

7.3.9 动作九：输出形式复核（第 14 条原则）

要回答：模型的输出是陈述句，还是征求认同的问句？

做法：抽查模型输出的原文，确认其形式是可独立核对的陈述句（"你今天的状态是 X"），而不是征求认同的问句（"你今天是不是 X？"）。

这是唯一能被审稿人直接验证"外部性未被诱导"的形式证据，而成本只是看一眼输出 —— 没有理由不做。

结果：陈述句占比 = 100%（2283/2283 句；来自 128 张卡 × 12 个方面）。全部输出均为可独立核对的陈述句，未发现任何征求认同的问句。

7.4 结果的呈现方式

7.4.1 反馈数据统计（表 7-5）

现有数据只覆盖主链。

表 7-5　反馈数据统计

指标	数值	备注
运行时间窗	2026-08-28 – 2026-09-13（17 天）	——
判定者人数	8	已定
模型每日产出条数	每张卡 12 个方面	——
判定总条数	128 个客户日（逐方面展开为 1536 个判定点）	12 个方面由日回复按规则展开
有效反馈数	日级 128（全部通过）；方面级 1481 符合 + 22 部分符合	日级为判定单位；方面级为展开
漏洞点数	日级 0；方面级 33	未通过判定的部分
判定通过率	日级 100%（128/128）；方面级 97.14%（计权）、96.42%（严格）	主报日级；方面级须注明分母由日回复展开
个体符合率（逐人，8 条）	8 条：0.872 – 0.995，中位数 0.982（逐条见表 7-6）	描述性统计，见表 7-6
漏洞点类型分布	已记归因 12 条，全部为「信息差 / 理解不同」；33 条不符合中 21 条未记归因	见图 3
其中"表达类抱怨"占比	0%（0/27，严格定义） / 7.4%（2/27，含两例边界）	P12
成簇污染案例数	0（观察期内未见）	P3
评分者间一致率	不适用	无共同评分对象， 在数学上无从计算

7.4.2 八条独立个案链（表 7-6）

每条个案 = 该人的个体符合率 + 代表性漏洞点 + 判定稳定性（若做 P9b）。

表 7-6　八条独立个案链

个案	判定条数	个体符合率	代表性漏洞点（脱敏后摘要）	判定稳定性（若做 P9b）
P-01	16	0.872	家庭及住宅、亲密关系、母亲关	未做

			系表征与性格底色混淆；「下属和子女」无对应生活情境	
P-02	15	0.978	2 条（未记归因）	未做
P-03	16	0.979	无「不符合」；8 条「部分符合」未记归因	未做
P-04	17	0.980	人格面具、健康管理、社会网络（未记归因）	未做
P-05	15	0.983	将当日状态与性格底色混淆；「讲秩序」判据被本人纠正（长期 vs 当日）	未做
P-06	17	0.990	内在精神世界 × 2（未记归因）	未做
P-07	16	0.992	亲密关系（未记归因）；另有 1 日因外部延迟未收到反馈	未做
P-08	16	0.995	1 条（未记归因）	未做
跨案汇总	128	中位数 0.982；范围 0.872 – 0.995	类型分布见图 3	见 7.3.4

跨案汇总只做描述（中位数、范围、类型分布），不做推断性统计（不做方差分析、不做配对比较 —— 因为它们都预设了"对同一对象的重复测量"，而本项目没有）。

7.4.3 一条反馈的完整走查

表 7-7　一条反馈的走查

步	发生了什么	落到哪里
1	模型每日自运行，生成该体验者当日的报告	模型输出

2	报告通过微信送达该体验者	——
3	体验者通过微信反馈"符不符合 + 是否和今天状态一致"	判定
4	若不符合，给出"不符合的点"	聊天记录
5	运营对接：收集、记下，并逐条记为「符合 / 部分符合 / 不符合」（不改写、不归纳、不解释）	原始材料
6	符合 → 有效反馈；不符合 → 漏洞点	反馈数据
7	沉淀为统计量	派生层

7.4.4 图 3：漏洞点类型分布

图 3　漏洞点类型分布〔图待绘制〕

图 3 呈现漏洞点的类型分布（若数据允许）。

7.5 证据的边界

边界一：证据只落在链条行为上。 本文的证据范围不含模型内部实现，也不含人因研究的方法细节；关于模型，本文只援引一条来源声明 ——"它由人因研究设计而来"（第 3 章 3.6）。因此没有一项证据来自模型内部指标（损失、参数量、训练数据规模）。这不是本文的疏忽，而是论证类型的规定 —— 本文要证明的是位置关系，不是内部机制。

边界二：无对照、无返工实测。本项目从未运行过传统路径，因此无法给出"用了本文路径比传统路径好多少"的比较。本文因此不主张"更快 / 更省"，只主张"污染在结构上进不来"。

只要不越界去声称"更优"，"无对照"就不构成威胁。

这一处由 P8 的阳性对照部分弥补（注入已知缺陷，看是否被判"不符合"）。

边界三：单案例、单产品、单团队、8 名自愿报名者。 结论限定在"该产品所服务的这一类自愿内测用户"，不外推到"所有具身机器人用户"；8 人用于探索与描述，不做统计推断。

边界四：两处无法完全排除的威胁。

- 巴纳姆效应不能完全排除 —— 即使问法是"对不对"型，"我今天的状态"本身仍是主观判断。→ P14 仍要做。
- 初始值锚定不能完全排除 —— 只能给出"产出超出初始值可推范围"的证据，不得声称已证明模型完全独立。→ P15 仍要做。

7.5.1 两处曾经的风险，现已排除

曾经担心	现状	转为正面表述
运营对接可能影响判定的外部性	已排除 —— 运营不向体验者解释模型的想法，只收集记下并逐条记录	这使"判定由外部体验者自主形成"成为可陈述的事实，而非假设。 已立为第 12 条原则「通道中立」
判定经微信回传，自由表达需逐条记为固定三值	已排除 —— 运营只收集、记下，三个取值都由体验者给出	判定的保真度完好。同样已立为第 12 条原则

本文最核心的论据（判据代表"人"、不代表"设计意图"→ 反驳循环论证）因此无需下调强度 P10 因此是本文最干净、最有力的一项检验。

7.5.2 伦理与隐私

50. 知情同意 —— 如何取得、以什么形式 [待补]；

51. 脱敏处理 —— 引文是否改写、是否去除可识别信息 [待补]；

52. 保存期限与访问权限 [待补]；

微信记录一并纳入上述伦理安排 —— 它是原始材料的主体，不能因为"渠道现成"就跳过伦理程序。

7.6 本章小结

本章把第 4 – 6 章的主张放到了一个真实产品上，交付了三样东西：

- 一个说清楚了的案例 —— 四条入选条件（人因驱动 / 模型先行 / 每日自运行 / 由外界内测体验者判定），其中第 4 条是本文"判据非自证"的物质基础；
- 九个分析动作，按成本排序，其中五个所需材料已经在手上；
- 一套呈现方式 —— 逐案呈现 + 跨案汇总（8 条独立个案链），而非"评分者间"。

第一，本章的六个动作不需要新采集任何数据。 这是因为：渠道是现成渠道（微信）→ 原始材料天然留存；模型每天自运行 → 历史输出已经积累。七项检验中，只有 P8（闸门对照）需要主动构造材料，P9b 需要主动抽取历史输出。

常规报告按"评分者间"组织，本项目不能这样组织 —— 因为 8 人不是 8 名评分者，而是 8 条独立个案。

无对照、单案例、8 名自愿报名者、两处无法完全排除的威胁 —— 这些都要写出来。"外部体验者判定"可以转成论据（它反驳了循环论证）。

第 8 章　讨论与有效性威胁

本文主张的是这条路径「可行」，不是它「更优」。 举证标准因此是存在性证明（有一个真实案例走通了），不需要对照组。

本文不涉及产品内部模型的具体实现，也不涉及人因研究的方法细节；关于模型，本文只援引一条来源声明 ——"它由人因研究设计而来"（第 3 章 3.6.1）。故本章的一切讨论都只涉及位置、结构与流程，不涉及内部机制。

本项目有四处质疑已经确认不成立（见 8.4）。

8.1 主张范围：本讨论的坐标系

本章的每一条判断，都是相对于"本文主张什么"来做的。 故先把坐标系重述一遍（同第 3 章 3.6.3）：

表 8-1　本讨论的坐标系

	内容
本文主张	这条路径能走通；以模型为出发点是可行的
本文不主张	这条路径优于传统路径（更快 / 更省 / 更准 / 返工更少）
举证标准	主张"可行" → 存在性证明 （有一个真实案例走通了） → 不需要对照组

这条坐标系直接消掉了一条常被列为"致命缺陷"的东西：

本项目从未运行过传统流程，因此没有返工实测、没有平行对照。按表 8-1，这与主张范围相匹配，不构成威胁。 需要补充的是，坐标系限定的是本文的举证责任，不是两条路径的差异：不主张"更优"，不等于两条路径没有差别 —— 污染位置、数据状态与链条形态三项差异可逐项核对（表 1-1、表 4-1），本文只如实列出、不作优劣判语；其中唯一无需对照组即可成立的一条，本文已作明确判断：通行路径在个体化生成场景下"不可行"（4.7.5）。

8.2 两类局限：结构性 vs 参数性

长期项目里的局限清单容易变成一锅粥："这个以后能修"和"这个永远修不了"混在一起写，结果是两类都失去说服力 —— 前者被读成拖延，后者被读成致命。

本文把局限分成两类，处理方式完全不同：

表 8-2　两类局限的处理方式

	结构性局限	**参数性局限**
来源	由命题推出 —— 它是结论的一部分	当前做法的边界 —— 与结论无关
能否消除	不能 （除非推翻前提）	能 （靠更多工作）

8.2.1 结构性局限（本文的，共三条）

（一）判定不可跨个体汇总为"对同一对象的评分"。

模型为每个人单独生成结果，各人各收一份、各评各的（第 4 章 4.7）。因此每个数据点属于不同的对象，且是模型为该对象定制的产物。

这不是"我们没做汇总"，而是汇总在数学上无从进行：一致率、方差分析、配对比较等一切"重复测量"性质的统计，其前提都是"对同一对象的重复观测" —— 本场景没有那个对象。

（二）判据是隐性的（未成文）。

"符合 / 不符合"的标准不在文档里。这一条的根在结构上：判据源于对人的研究、由模型承载，而该研究的方法细节不在本文的证据范围内（第 3 章 3.6）—— 本文无法把判据完整写成文字，因为它从来就不是以文字形式存在的。

缓解（但非消除）：原始材料保留（录音 / 聊天），判据可事后反推成文（第 5 章第 9 条原则）。

（三）本文的主张天然是"存在性"的，不含强度信息。

本文证明的是"能走通"，不是"走得好"。这不是本文的取舍，而是举证标准使然（表 8-1）。

写出来是自律，被问出来是漏洞。

8.2.2 参数性局限（本文的，共四条）

#	局限	现状	改进路径
1	样本规模与来源	判定者 8 人， 网上发帖自愿报名 → 自选偏差 （可能偏技术爱好者 / 早期采用者） + 探索性小样本	扩大样本；改用分层招募。
2	表达层为 MVP 版本	会出现难懂表述 → "看不懂"可能被判成"模型不对"，渗入主链数据	用现有数据做 P12 检验 （对漏洞点做内容编码，统计表达类抱怨占比）； 材料已在手上
3	意见通路尚未接入	涉及"意见 → 表达层"的论断（P6、 P11 落地形态） 无运行数据	阶段二建通路； 先用 P11 的回溯性可行性检验在建通路前证明"分得开"
4	判据未成文（可缓解部分）	见 8.2.1 （二）	用留存原料反推成文；判定前先让体验者独立记录当日状态，与模型输出分离采集

第 2 条是四条里最要紧的：它的风险位于分流的上游，提取内核挡不住，且阶段一就在跑。

8.3 有效性威胁

按 cs.SE 通行的四类逐条列出。每条都给出"本文怎么应对"，答不了的如实写"本文答不了"。

表 8-3　有效性威胁清单

类型	威胁	应对
构念效度	判据隐性（未成文）	① 如实声明（8.2.1 二）； ② 不计算"评分者间一致率" —— 确认无共同评分对象，该指标不适用，改为 P9b 判定者内稳定性 （抽历史输出让本人重评）； ③ 用留存原料反推判据成文； ④ 把"判据从隐性到显性"本身当作研究对象

构念效度	样本为自愿报名者	① 说明招募渠道、人数与人群特征； ② 结论限定在"该产品所服务的这一类自愿内测用户"，不外推到"所有具身机器人用户"； ③ 声明 8 人用于探索与描述，不做统计推断
构念效度	巴纳姆效应 （[16] Forer 1949）	① 判定的问法是"符不符合 + 是否和你今天状态一致"，不是"像不像在说你" → 属"对不对"型问法， 力度显著下调； ② 但不能完全排除 → P14 错配对照仍要做 （把 A 的报告给 B 看）； ③ 如实报告结果，不回避
构念效度	参照物的独立性	大多数是内省；模型只客观给出当日状态、无引导词汇 → 基本排除。改进路径 = 判定前分离采集
构念效度	初始值的锚定 / 路径依赖	① 内容编码统计输出与初始值的重合比例；② P15 划出初始值的信息量上限；
构念效度	"输入"一词的歧义	"输入枯竭"只针对前者；
内部效度	分类权落在运营同事的「提取内核」工序上	① 明确区分"反馈数据被污染"与"模型被污染" （后者不会发生）； ② 明确声明该工序尚未运行 → 风险面向下一步，不是当前问题； ③ 用 P11 回溯性可行性检验在建通路前证明"分得开"； ④ 声明两条硬约束（只归类、不改写 + 原始材料留存且可对照）； ⑤ 如实报告"无法归类"的条目比例
内部效度	从未运行传统路径 → 无对照	这不是威胁，而是与主张范围匹配 （表 8-1）。
外部效度	单案例、单产品、单团队	声明；结论限定在"这一类研发路径"，而非"所有具身机器人的研发"
外部效度	表达通路尚未接入	① 如实标为下一步工作，不当作既成事实； ② 指出它不威胁主链主张 —— 意见通路本就与主链无关， 主链证据反而因此更纯粹
信度	"符合 / 不符合"由体验者直接	可靠性由三条共同保证： (a)

	给出 → 无第二道把关	P9b 判定者内稳定性 + (b) 判定确由本人作出 + (c) 传递环节不污染（第 12 条原则）。
信度	判定的时间粒度	逐日判定 → 有时间序列（收益：趋势分析 + 个体内跨日稳定性）。
信度	判定标准可能随时间漂移	① 保留判定日志；② 分时段比较个体符合率；③ 同一人跨时间点自比是可行的漂移检验。
伦理与隐私	原始材料含录音、微信记录等个人信息	① 说明知情同意方式；② 说明脱敏处理（引文是否改写、是否去除可识别信息）；③ 说明保存期限与访问权限；④ 正文引例一律脱敏；⑤ 微信记录一并纳入

8.3.1 本文答不了的两条

（一）本文无法排除"锚定"的完全影响。 模型以用户的初始值为起点，每日产出可能只是初始值的缓慢展开。P15 能给出"产出超出初始值可推范围"的证据，但给不出"完全独立"的证明。 本文不声称后者。

（二）本文无法把判据写成文字。 见 8.2.1（二）。反推成文得到的是本文对判据的重构，不是判据本身。

主动写出"我答不了什么"，比让审稿人发现"你没答这个"代价小得多 —— 而且它反过来证明本文清楚自己论证的边界在哪。

8.4 已排除的四条质疑：转为正面表述

本项目有四处质疑已经确认不成立。它们不得留在局限清单里 —— 那等于自己替审稿人扣分。正确的处理是正面写出，并说明它是怎么被排除的。

表 8-4　四条已排除的质疑及其正面表述

#	曾被担心的质疑	结论	正面表述方式
1	回声 / 自证性（模型只是把用户的输入还给他，"符合"必然成立）	不成立 —— 三重排除	① 用户主动输入是一次性的（此后不再提供）→ 没有持续复述的机会；② 推演素材

			来自用户未主动告知的信息 → 用户不知道模型看到了什么；③ 输出每天都不一样 → 若是回声，输出应当静止。 → 这使「符合」一词的含义成为可陈述的事实：「模型说中了他的状态，而不是复述了他的输入」
2	措辞诱导 （即使说中了，诱导性措辞也会人为拉高符合率）	不成立	模型只是客观地给出当日状态，没有引导词汇。 → 立为第 14 条原则「陈述不引导」，与第 12 条构成一对。 可被审稿人复核的形式特征：输出是可独立核对的陈述句 （"你今天的状态是 X"），而非征求认同的问句 （"你今天是不是 X？ "）
3	运营对接影响判定的外部性 （运营知道设计意图，若解释或引导则判定不再外部）	不成立	运营不向体验者解释模型的想法，只收集、记下并逐条记录。 → 立为第 12 条原则「通道中立」。它使"判定由外部体验者自主形成"成为可陈述的事实，而非假设
4	判定经微信回传，自由表达需逐条记为"符合 / 部分符合 / 不符合" （由谁定成？）	不成立	运营只收集、记下，把体验者的回复按 12 个方面逐条记为三值，不改写、不归纳。 → 判定的保真度完好，判定是一手数据

第 1 条与第 2 条合起来是本文的一个实质优势：措辞诱导比巴纳姆效应更隐蔽（巴纳姆靠描述模糊，诱导靠问法施压），能排除掉它不是理所当然的 —— 它是第 14 条原则被真正执行的结果。

第 3 条与第 4 条使本文最核心的论据无需下调强度：判定确实是由外部体验者自主形成的，本文可以把它写成硬的结构事实。

8.5 本文不主张什么

前面各章的"不主张"分散在各处，这里集中列一次 —— 便于审稿人一次看清。

表 8-5　本文的边界汇总

#	本文不主张	出处
1	不主张这条路径更优 （更快 / 更省 / 更准 / 返工更少）	3.6.3
2	不描述模型的内部实现 （结构、损失、参数量、训练数据规模）	3.6
3	不描述人因研究的方法与产出形式	3.6
4	不作机制性论证 （不主张"为什么这样设计会有效"）	3.6
5	不写"参照物完全独立于模型" —— 只能说"以体验者内省为主"	4.9 / 8.3
6	不声称已证明模型完全独立于初始值 —— 只能说"产出超出初始值可推范围"	4.8 / 8.3.1
7	不把判定跨个体汇总为"对同一对象的评分"；不使用一致率 / 方差分析 / 配对比较	4.7
8	不声称巴纳姆效应已完全排除 —— P14 仍要做	4.9 / 6.2
9	不声称已建立"个性化生成内容评估"的完整方法学	8.6.3
10	不把"已内建于设计"写成"已被验证" （第 1、 2、 3、 4、 5、 6、 8 条原则）	5.7

表 8-5 列出十条"不主张"，其作用是保证：凡是留下来的主张，都不需要本文没有的数据。对一项证据基础只覆盖部分环节的案例研究而言，这是唯一可行的处理方式。 其中第 1 条还需一层分寸：不主张"更优"是举证责任上的自我约束，不是对两条路径差异的否认 —— 差异已逐项列于表 1-1 与表 4-1，本文只列差异、

不作优劣判断；而"通行路径在个体化生成场景下不可行"属结构性事实，已在 4.7.5 予以论证。

8.6 与既有研究的关系

本节只作定位，不作详尽比对 —— 详尽的文献比对属于第 2 章（相关工作）。本节引用的文献均已核实。

8.6.1 本文落在五条脉络的交叉处

脉络	本文的位置
人因驱动的机器人研发 / HRI	本文的起点即"先研究人"；与 HRI 的人因传统同源（[1] Goodrich & Schultz 2008； [2] Sheridan 2016）
软件验证与确认（V&V）	本文的"验证"落在 SE 的 V&V 传统里 —— 判据、证据、可追溯；与 V&V 标准的过程观一致（[4] IEEE 1012-2016； [5] ISO/IEC/IEEE 12207:2017； [6] Boehm 1984）
需求工程与人因需求	"判据源于对人的研究"是需求工程的老问题的新形态（[7] Viller et al. 1999； [8] Sutcliffe 1998）
data-centric vs model-centric AI	本文与 data-centric AI 的默认前提直接冲突 —— 见 8.6.2 （[9] Zha et al. 2023；[10] Whang et al. 2023）
ML 系统工程化（MLOps / 数据治理 / 技术债）	本文讨论的是流程与边界，不是工具链；与"技术债源于系统耦合"的诊断同构（[12] Sculley et al. 2015； [13] Kreuzberger et al. 2023； [14] Gebru et al. 2021）

8.6.2 核心张力：本文在 data-centric AI 的语境下是"异端"

data-centric AI 的核心主张是：模型的质量取决于数据的质量，故应把工程投入放在数据上。 本文主张的是：模型不取自数据，因此数据污染在结构上进不来。

这两者并不矛盾 —— 它们在不同的前提上运作。 本文的前提是：模型不是学来的，是设计出来的（第 3 章 3.2）。一旦模型不是从数据学来的，"提升数据质量以提升模型"这条路径在本文的场景里就不存在。

本文只主张：在"模型由人因研究设计而来"这一前提下，data-centric 的那条路径不适用。这是一个有条件的主张，条件就写在 8.5 第 3 条上（本文不描述那项研究怎么做）。

8.6.3 方法学归属：本文的验证形态落在 SCD / N-of-1 里

本文的验证是"每人各评各的、无共同评分对象"。这一形态在方法学上落在既有的「单被试设计（single-case design, SCD）/ N-of-1 trial」框架内 —— 该框架以单个个体为分析单位，设计前提正是"不把跨个体的观测汇总为对同一对象的重复测量"。

文献	内容
[18] Vohra, S., et al. (2015). CONSORT extension for reporting N-of-1 trials (CENT) 2015 Statement. BMJ, 350 , h1738.	N-of-1 试验的报告规范
[19] Tate, R. L., et al. (2016). The Single-Case Reporting Guideline In BEhavioural Interventions (SCRIBE) 2016 Statement. American Journal of Occupational Therapy, 70 (4), 544 – 555.	

引用性质（2026-10-08 定）：这是"定位"，不是"依据"。它说明本文的验证形态有方法学归属，不说明本文的结论已被该传统支持 —— 本文的结论仍只由第 3 – 7 章自己的证据支撑。

53. 正面的：本文说"评分者间一致率不适用"时，替代方案不是临时发明的，它有既有方法学归属（第 6 章 6.4.1）。这使那条方法论要点从"辩解"变成"定位"。
54. 负面的：未找到专门针对"AI 个性化生成内容"的评估方法学文献 —— 这是一处真实的空白。

8.7 对未来工作的指引

本节只列"能做什么"，不承诺"一定能成"。

表 8-6　下一步工作（按成本排序）

优先	工作	材料状态	说明
1	P12 内容编码 （统计漏洞点里"表达类抱怨"占比）	已在手上	成本最低、最先能出结果； 直接检验 8.2.2 第 2 条这条最要紧的

			参数性局限
2	P14 错配对照 （把 A 的报告给 B 看）	已在手上	成本极低； 两种结果都是收获 （下降 → 判定有区分度；不下降 → 如实报告）
3	P9b 判定者内稳定性（抽历史输出让本人重评）	需回溯补做	本场景下唯一可行的信度检验 （第 6 章 6.4）
4	P11 分流可行性检验（两名独立编码者分类、算一致率）	需做	在建通路之前判断分流是否可行
5	判据反推成文 （用留存原料）	已在手上	产出是"本文对判据的重构"
6	P15 信息增益 （输出与初始值的重合度）	需编码	
7	分流接入（阶段二）	未启动	接入后 8.2.2 第 3 条才能解除
8	表达层改进	能力已具备	注意： 这是本文有意推迟的一环 （第 4 章 4.6），推迟本身就是"模型最重要"的行为证据

故多案例不是本文的必要后续 —— 它是"把结论外推"的工作，属另一篇论文的范围。

8.8 小结

本章做了三件事：

55. 钉死坐标系（8.1） —— 本文主张"可行"、不主张"更优"；举证标准是存在性证明，不需要对照组。"无对照"因此与主张范围匹配，不构成威胁。
56. 把局限分成两类（8.2） —— 结构性局限（不可跨个体汇总 / 判据隐性 / 主张的存在性）写成结论；参数性局限（样本、表达层、通路、判据成文）如实写出并给改进路径。
57. 逐条列出有效性威胁（8.3），并把四条已排除的质疑转为正面表述（8.4），最后把全文的"不主张"汇总成一张表（8.5）。

本文的每一条主张，都不需要本文没有的数据。 其原因不是数据充足，而是主张范围被有意收窄：没有任何一条主张需要靠"没有对照"或"内部机制"来支撑。

第 9 章（结论）不应提出新的主张，只应收束本章与第 3–7 章已经立住的东西，并把落点放在"希望读者做什么"上。

第 9 章　结论

9.1 本文主张了什么

9.1.1 一句话

「模型 → 验证 → 数据」这条路径是可行的；在这条路径上，模型是出发点，也是最重要的一环。

9.1.2 三条贡献，以及各自被什么支撑

表 9-1　三条贡献与其支撑

#	贡献	立在哪	靠什么支撑
C1	提出一条路径，并与通行路径逐项对照；说明其结构性优势是污染阻断 （不是"抗污染能力强"）；并说明在个体化生成场景下，通行路径不是"不优"而是"不可行"	第 3、 4 章	结构性证据 —— 每个数据点属不同对象、且是模型为该对象定制的产物 → 既不能汇集、也不能反哺
C2	14 条可复用的设计原则，每条配一个「违反它会怎样」的失败模式	第 5 章	行为类证据两条 —— ① 资源分配的优先序（表达层便宜却有意推迟）； ② 输入一次即枯竭而输出持续且每日不同
C3	可证伪的检验方案 —— 3 条认输条件 + P1 – P15，其中七条可实操；并以一个真实产品做单案例研究	第 6、 7 章	单案例实证 —— 8 条独立个案链，逐案呈现 + 跨案汇总

三类证据互不依赖 —— 这是本文论证的基本设计（第 4 章 4.11）。

9.1.3 本文最硬的一段

若要只留一句技术性的话，是这一句：

在本场景中，每个数据点属于不同的对象，且是模型为该对象定制的产物。这类数据既不能汇集，也不能反哺模型。因此「数据 → 模型」不是"不优"，而是"不可行"。

它把本文的立论从"我们选择这样做"升级为"数据结构逼我们这样做"（第 4 章 4.7.5）。

它之所以最难被反驳，是因为它不依赖模型内部：它只说数据的形状，不说模型的机制。而数据的形状在本文的可见范围之内（第 3 章 3.6）。

9.2 本文没有主张什么

表 8-5 列出十条"不主张"，其作用是保证：

凡是留下来的主张，都不需要本文没有的数据。

具体地说：不主张更优 → 不需要对照组；不描述模型内部 → 不需要内部指标；不描述人因研究的方法 → 不需要那项研究的细节；不声称巴纳姆效应已完全排除 → 不需要把 P14 做成"已解决"。

对一项证据基础只覆盖部分环节的案例研究而言，这是唯一可行的处理方式。这一分寸的边界还需再明确一次：不主张"更优"，是为了不越过举证责任，而不是为了抹平两条路径的差异 —— 差异可逐项核对（表 1-1、表 4-1），本文只如实列出而不代下结论；而"通行路径在个体化生成下不可行"不依赖对照组即可成立，本文已就此作出明确判断（4.7.5）。

9.3 这条结论在什么条件下成立

本节汇总第 3 – 7 章已经确立的前提，不新增条件。

"可行"不是一个无条件成立的判断。把本文成立所依赖的前提集中写出来，读者才知道能把它用到哪里：

表 9-2　本文结论成立的前提

#	前提	出处	若不成立会怎样
1	模型来自对人的研究，而不是来自数据	第 3 章	本文路径的起点消失 —— 整条论证失去前提

2	存在一名外部判定者，且他不了解设计意图	第 4 章（第 10 条原则）	判定退化为设计方自我确认 → 循环论证
3	判定问的是"对不对"，不是"像不像"	第 4 章 4.8	判定失去区分度 → 巴纳姆效应接管
4	判定由输出所指向的那个人本人给出，不跨个体汇总	第 4 章 4.7 （第 13 条原则）	数据失去可比对象 → 只能做描述，不能做推断
5	传递环节只做逐条记录，不解释、不改写判定内容	第 5 章（第 12 条原则）	外部性被绕过 → 第 2 条前提失效
6	模型以陈述方式给出判断，不使用引导性措辞	第 5 章（第 14 条原则）	符合率被人为拉高 → 判据失去意义

前两条是结构性的（不满足则路径不成立），后四条是防护性的（不满足则证据不成立）。它们与第 8 章 8.2 的两类局限是同一组事实的两种读法：作为局限读，是"本文的边界"；作为条件读，是"你要复制时得先满足什么"。

结论限定在"这一类研发路径"上，不外推到"所有具身机器人的研发"，更不外推到"所有具身机器人用户"（第 8 章 8.3）。

9.4 希望读者读完做什么

9.4.1 一件事

把「先有什么」当成研发流程设计里一个必须先回答的问题。

在设计自己系统的流程时，主动回答"模型从哪来" —— 而不是默认「先采数据」。

表 9-3　一件事在不同角色上的投影

读者角色	**这件事具体是什么**
系统架构 / 流程设计者 （主读者）	在流程设计阶段， 显式回答"模型从哪来"，并据此判断污染的位置在哪、数据的性质是原料还是产物
方法学研究者	注意本文指出的那处空白 —— "AI 个性化生成内容的评估"尚无现成方法学；本文只做了定位（落在 SCD / N-of-1 框架内）， 没有建立它

产品 / 研发团队	若要复制，先对照表 9-2 的六条前提，特别是第 2 条（外部判定者）与第 5 条（传递只做逐条记录） —— 这两条决定证据成不成立

主读者的那一件事只有一个（9.4.1）。

9.4.2 为什么要求的强度只到这里

58. 那句话里藏着一个本文没有证明的前提。 "你应该改用"隐含"它更好"；而本文只证明可行，没有证明更优（8.1）。若在这里越界，第 8 章 8.3 那条"无对照"会当场从无害变成致命。
59. 要求的强度必须与证据的强度一致。 本文的证据是单案例、探索性的 —— 它担得起"值得问一次"，担不起"改用它"。要求读者"问一次"是本文证据担得起的；要求读者"改"是担不起的。
60. "值得被问一次"不依赖任何比较性结论。 无论这条路径是否更优，"先有什么"都是一个该被回答的问题 —— 这个要求的成立不需要本文赢过任何对手。

所以本文对读者的要求，强度上限就是"值得问一次"，不是"必须改"。

这样写反而更有力：一个被明确限定过的要求，比一个被夸大的要求更难被驳回。前者审稿人只能接受或无视；后者审稿人只需举出一个反例。

9.4.3 如果你决定这么做：可以拿走什么

可拿走的东西	在哪	性质
14 条设计原则，每条配失败模式	第 5 章	10 / 11 / 12 / 13 / 14 已在运行且有事实支撑； 1/2/3/4/5/6/8 已内建于设计、未单独取证； 9 有改进路径； 7 是目标状态
七项可实操的实证设计 （P9a / P9b / P10 / P11 / P12 / P14 / P15）	第 6 章	其中多数材料已在手上，成本低
一处已定位的方法学空白	第 8 章 8.6.3	指出"AI 个性化生成内容的评估"尚无现成方法学 —— 本文没有建立它
一张边界表 （十条"不主张"）	第 8 章 8.5	供复制这条路径的人对照自查

9.5 下一步

表 9-4　下一步工作，按能否立即开始分组

组	项	状态
可立即做 （材料已在手上）	P12 内容编码 （统计漏洞点里"表达类抱怨"占比） / P14 错配对照 （把 A 的报告给 B 看） / 判据反推成文 （用留存原料）	三项材料均在手上， 成本最低
需回溯补做	P9b 判定者内稳定性 （抽历史输出让本人重评） / P11 分流可行性检验 （两名独立编码者分类）	需先拟规则 / 联系判定者
需额外编码	P15 信息增益 （输出与初始值的重合度）	
需启动新阶段	分流接入（阶段二） —— 建规则 → 提取意见 → 接入语料库表达层	未启动；接入后 8.2.2 第 3 条才能解除
需能力投入	表达层改进	能力已具备。注意：这是本文有意推迟的一环 —— 推迟本身就是"模型最重要"的行为证据（第 4 章 4.6）

9.6 一句话

在个体化生成的场景里，「数据 → 模型」不是不优，而是不可行；因此「模型 → 验证 → 数据」不是一种偏好，而是一种被数据结构逼出来的形态。本文证明的是它可行 —— 至于读者要不要把它当成一个问题来回答，那是读者的事。

参考文献

[1] Goodrich, M. A., & Schultz, A. C. (2008). Human–Robot Interaction: A Survey. Foundations and Trends in Human-Computer Interaction, 1(3), 203–275. DOI: 10.1561/1100000005

[2] Sheridan, T. B. (2016). Human–Robot Interaction: Status and Challenges. Human Factors, 58(4), 525–532. DOI: 10.1177/0018720816644364

[3] He, W., Li, Z., & Chen, C. L. P. (2017). A survey of human-centered intelligent robots: issues and challenges. IEEE/CAA Journal of Automatica Sinica, 4(4), 602–609. DOI: 10.1109/JAS.2017.7510604

[4] IEEE. (2017). IEEE Std 1012-2016: IEEE Standard for System, Software, and Hardware Verification and Validation. IEEE. DOI: 10.1109/IEEESTD.2017.8055462

[5] ISO/IEC/IEEE. (2017). 12207:2017 Systems and software engineering — Software life cycle processes. ISO/IEC/IEEE. DOI: 10.1109/IEEESTD.2017.8100771

[6] Boehm, B. W. (1984). Verifying and Validating Software Requirements and Design Specifications. IEEE Software, 1(1), 75–88. DOI: 10.1109/MS.1984.233702

[7] Viller, S., Bowers, J., & Rodden, T. (1999). Human factors in requirements engineering: A survey of human sciences literature relevant to the improvement of dependable systems development processes. Interacting with Computers, 11(6), 665–698. DOI: 10.1016/S0953-5438(98)00049-6

[8] Sutcliffe, A. (1998). Scenario-based requirements analysis. Requirements Engineering, 3(1), 48–65. DOI: 10.1007/BF02802920

[9] Zha, D., et al. (2023). Data-centric Artificial Intelligence: A Survey. arXiv:2303.10158v3.

[10] Whang, S. E., et al. (2023). Data collection and quality challenges in deep learning: a data-centric AI perspective. The VLDB Journal, 32(4), 791–813. DOI: 10.1007/s00778-022-00775-9

[11] Motamedi, M., et al. (2021). A Data-Centric Approach for Training Deep Neural Networks with Less Data. arXiv:2110.03613v2（NeurIPS 2021 Data-Centric AI Workshop）.

[12] Sculley, D., et al. (2015). Hidden Technical Debt in Machine Learning Systems. Advances in Neural Information Processing Systems 28 (NIPS 2015), 2503–2511.

[13] Kreuzberger, D., Kühl, N., & Hirschl, S. (2023). Machine Learning Operations (MLOps): Overview, Definition, and Architecture. IEEE Access, 11, 31866–31879. DOI: 10.1109/ACCESS.2023.3262138

[14] Gebru, T., et al. (2021). Datasheets for Datasets. Communications of the ACM, 64(12), 86–92. DOI: 10.1145/3458723

[15] Sculley, D., et al. (2014). Machine Learning: The High Interest Credit Card of Technical Debt. SE4ML: Software Engineering for Machine Learning (NIPS 2014 Workshop).（无 DOI）

[16] Forer, B. R. (1949). The fallacy of personal validation: A classroom demonstration of gullibility. The Journal of Abnormal and Social Psychology, 44(1), 118–123. DOI: 10.1037/h0059240

[17] von Neumann, J. (1958). The Computer and the Brain. New Haven: Yale University Press.（中译本：《计算机与人脑》，甘子玉译，商务印书馆，ISBN 7-100-03244-X）

[18] Vohra, S., et al. (2015). CONSORT extension for reporting N-of-1 trials (CENT) 2015 Statement. BMJ, 350, h1738. DOI: 10.1136/bmj.h1738

[19] Tate, R. L., et al. (2016). The Single-Case Reporting Guideline In BEhavioural Interventions (SCRIBE) 2016 Statement. American Journal of Occupational Therapy, 70(4), 544–555. DOI: 10.5014/ajot.2016.704002

[20] Maguire, M. (2001). Methods to support human-centred design. International Journal of Human-Computer Studies, 55(4), 587–634. DOI: 10.1006/ijhc.2001.0503

[21] Sutcliffe, A., Fickas, S., & Sohlberg, M. M. (2006). PC-RE: a method for personal and contextual requirements engineering with some experience. Requirements Engineering, 11(3), 157–173. DOI: 10.1007/s00766-006-0030-0